

機械学習システム
セキュリティガイドライン
Part II. 「リスク分析編」

Version 2.00 β
2023 年 6 月 28 日

機械学習システムセキュリティガイドライン策定委員会
機械学習セキュリティワーキンググループ[†]

日本ソフトウェア科学会 機械学習工学研究会



本ガイドラインの著作権は、執筆を担当した各委員に属します。

第1版からの変更点：

- ・訓練データの定義など、軽微な説明の追加・修正(II-2.1, II-5.1)
- ・機械学習の種類と攻撃被害の対応表の追加(II-3.2)
- ・セキュリティリスク分析のフレームワークの説明の追加(II-4.2)
- ・開発者向けのリスク分析の説明の追加(II-5.3)
- ・開発者向け影響分析の説明の大幅な追加(II-6)
- ・開発者向け影響分析の実現例の追加(II-7)
- ・第1版で「リスク分析」としていた分析を「脅威分析」に名称変更(II-8など)
- ・開発者向け脅威分析技術に物体検知AI、AutoMLへの対応、攻撃シナリオを追加(II-9)
- ・セキュリティリスク分析の試行例に影響分析を追加し、影響分析と脅威分析の結果を受けた判断の説明を追加(II-10)
- ・まとめ、参考文献、メンバーリストの追加・修正(II-11,II-12,メンバーリスト)

目次

II-1. はじめに	II-1
II-2. 本ガイドラインで扱う機械学習システムについて	II-2
II-2.1. 機械学習システムの構成	II-2
II-2.2. 機械学習システムの開発プロセス	II-3
II-3. 機械学習システムセキュリティの概要	II-4
II-3.1. 機械学習への攻撃	II-4
II-3.2. 攻撃による被害について	II-4
II-4. 機械学習システムを守るには	II-6
II-4.1. 機械学習システムを守る手段	II-6
II-4.2. 機械学習システムにおけるセキュリティリスク分析	II-6
II-4.3. 通常のITセキュリティとの関係	II-7
II-5. 機械学習システム開発プロセスにおけるリスク分析	II-8
II-5.1. 機械学習システム特有の攻撃に対するセキュリティを考慮した開発プロセス	II-8
II-5.2. 機械学習システム向けのリスク分析技術について	II-10
II-5.3. AI開発者向けリスク分析	II-10
II-6. AI開発者向け影響分析	II-12
II-6.1. AI影響分析	II-12
II-6.1.1. 機械学習セキュリティ専門家による事前準備手順	II-13
II-7. AI影響分析の実現例	II-14
II-7.1. 影響分析ワークシート	II-14
II-8. AI開発者向け脅威分析	II-19
II-8.1. 選択回答式AIセキュリティリスク問診（AIリスク問診）	II-19
II-8.1.1. 機械学習セキュリティ専門家による事前準備手順	II-19
II-8.1.2. 分析者による分析手順	II-23
II-9. AIリスク問診の実現例	II-26
II-9.1. 注意事項	II-26
II-9.2. アタックツリーと攻撃実施可能条件	II-26
II-9.2.1. 回避攻撃（敵対的サンプル）のアタックツリーと攻撃実施好条件	II-28

機械学習システムセキュリティガイドライン Part II. 「リスク分析編」

II-9.2.2.	ポイズニング攻撃のアタックツリーと攻撃実施可能条件	II-32
II-9.2.3.	モデル抽出攻撃のアタックツリーと攻撃実施可能条件	II-35
II-9.2.4.	モデルインバージョン攻撃のアタックツリーと攻撃実施可能条件	II-39
II-9.2.5.	メンバシップ推測攻撃のアタックツリーと攻撃実施可能条件	II-41
II-9.3.	質問群	II-46
II-9.4.	攻撃実施可能条件の満足状況の判定用テーブル	II-51
II-9.5.	AI リスク問診ツール	II-54
II-10.	セキュリティリスク分析の試行例	II-55
II-10.1.	事例試行概要	II-55
II-10.1.1.	融資審査 AI	II-55
II-10.1.2.	プラント制御 AI	II-74
II-10.1.3.	性別・年齢推定 AI	II-83
II-11.	まとめ	II-108
II-12.	参考文献	II-109
	機械学習システムセキュリティガイドライン策定委員会メンバーリスト	II-111

II-1. はじめに

本ガイドラインは、機械学習システムの開発者（AI開発者）が開発する機械学習システムについて、機械学習特有の攻撃の観点でどのようなセキュリティリスクや脆弱性があるかを、開発者自身で分析する手法に関するガイドラインである。本ガイドラインはAI開発者が参照するための参考情報として位置づける（強制力はない）。本ガイドラインにおける「AI開発者」は必ずしも機械学習セキュリティの専門知識を有する必要はなく、一般の機械学習システム開発者を想定する。本ガイドラインは「機械学習システムセキュリティガイドライン本編」に示される一連の手順において、AI開発者による脅威分析の部分に相当し、具体的な分析手法を紹介する。別書「攻撃検知技術の概要」では、AI開発者が攻撃の検知技術を検討する際に参考となる情報を提供するのでこちらも参照されたい。なお、紹介する脅威分析の実現例は2022年12月現在の状況であり、攻撃アルゴリズムが今後進化した場合には、対応できなくなる可能性を含めて再度検討する必要がある。また、実現例は本ガイドラインの筆者が検討したものであり、これまでに発表されている全ての攻撃に対応したものではない。

II-2. 本ガイドラインで扱う機械学習システムについて

この章では本ガイドラインで対象とする機械学習システムについて整理する。

II-2.1. 機械学習システムの構成

本ガイドラインで対象とする機械学習システムは、機械学習(Machine Learning)を用いたシステムである。機械学習システムの機械学習処理部は訓練パイプラインと推論パイプラインから構成されるのが一般的であり、図 II- 1、図 II- 2 のように表すことができる。システムによっては訓練処理を外部で行い、推論パイプラインしか行わないシステムも存在する。機械学習システムの運用に先立って、訓練パイプラインにて大量の訓練データを用いて訓練処理を行い、訓練済みモデルを生成する。そして、推論パイプラインにて推論対象データと訓練済みモデルを用いて推論処理を行って推論結果を得る。機械学習システムの構成は必ずしも、図 II- 1、図 II- 2 のものとは限らないが、本ガイドラインの内容はシステムの構成に合わせて適宜読み替えて頂きたい。なお、本ドキュメントでは、以後、単に「訓練データ」と記述した場合には図 II- 1 の訓練データ、バリデーションデータ、テストデータの全ての総称とする。

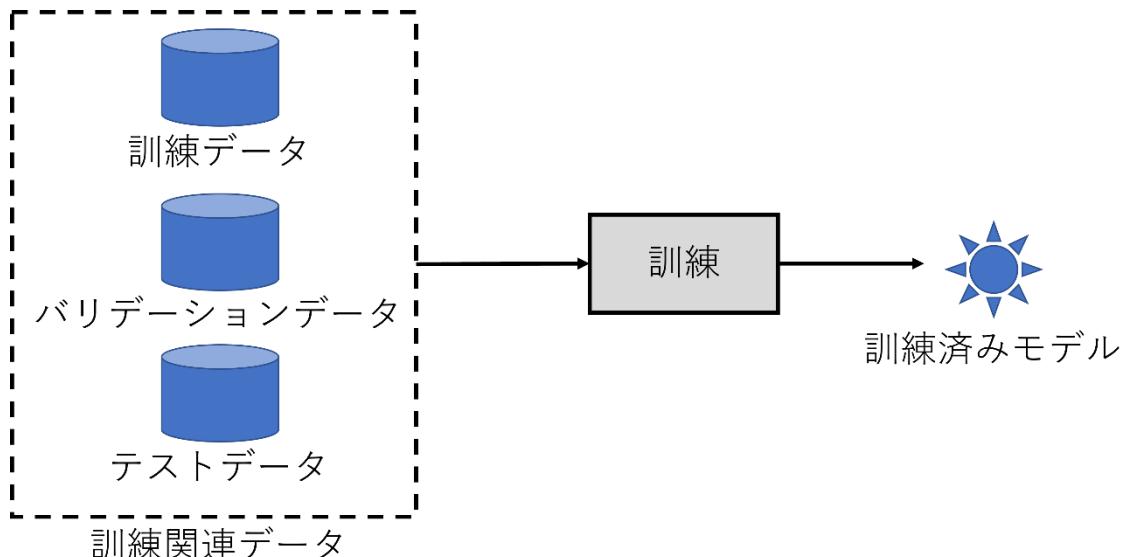


図 II- 1. 機械学習システムの訓練パイプライン

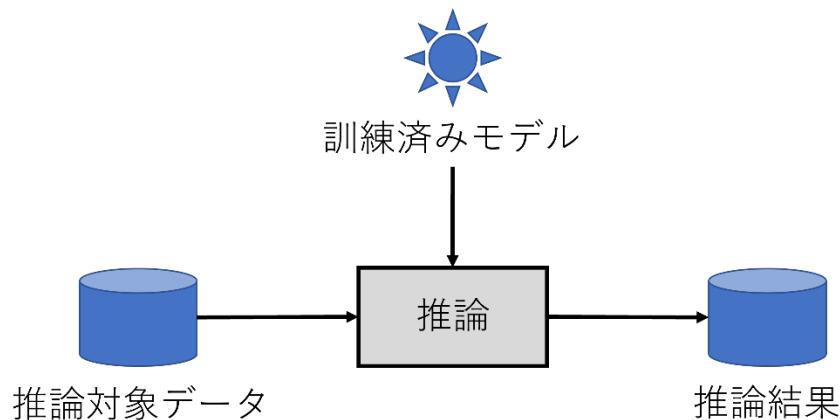


図 II- 2. 機械学習システムの推論パイプライン

II-2.2. 機械学習システムの開発プロセス

一般的な IT システムの開発と異なり、機械学習システムの開発時には、顧客からの要求に答える機械学習システムを開発するために、設計した後で試作を行い、精度や性能を評価してから正式な開発に移るケースが多い。試作の結果、期待する性能が出ていなかった場合には設計からやり直すこともある。このような試行を含んだ、機械学習システムの機械学習処理部における開発プロセスの一例を図 II- 3 に示す。この図は、機械学習システムセキュリティガイドライン本編 I-1.3.1 節で参照した総務省 AI ネットワーク社会推進会議の AI 利活用ガイドライン [II-1] における利活用の流れのうち、AI 構築部のみにフォーカスを当てて記載したものである。本ガイドラインでは、このような開発プロセスにセキュリティリスク分析のフェーズを入れることを検討する。検討結果は II-5 章で説明する。

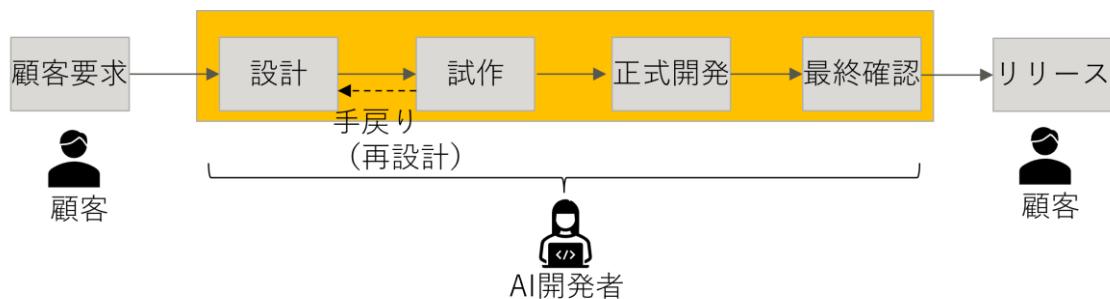


図 II- 3. 機械学習システムの機械学習処理部における一般的な開発プロセス

II-3. 機械学習システムセキュリティの概要

この章では本ガイドラインで扱う機械学習システムへの攻撃手法やその被害について整理する。

II-3.1. 機械学習への攻撃

近年、機械学習システムに対する機械学習特有の攻撃の存在が指摘されている。この攻撃は、機械学習システムに正当にアクセスしているにも関わらず、機械学習が間違えた判断をしたり、訓練データや訓練済みモデルを盗んだりしてしまうものである。攻撃者は、常に正当なアクセス権を保有して、システムを正常に操作する。システム側から見ると正常な処理であり、正当なアクセスとの区別が困難である。この点において、一般の情報セキュリティ分野における攻撃とは異なっている。(情報セキュリティ分野における攻撃では、システムに異常なデータを入力するなどしてシステムを誤動作させるものは多い)。機械学習への代表的な攻撃は機械学習システムセキュリティガイドライン本編 I-2.2 節、及び、表 II- 1 にまとめる。これらの代表的な攻撃は攻撃の種類を表しており、同じ攻撃の種類であってもそれを実施するための手段(攻撃アルゴリズム)は複数存在する。例えばモデル抽出攻撃に対して、複数の実施手段(攻撃アルゴリズム) [II-11][II-12] が存在する。

表 II- 1. 機械学習への代表的な攻撃

攻撃による被害	攻撃の種類	攻撃の内容
訓練済みモデルの判断を誤らせる	回避攻撃 (敵対的サンプル)	推論時に機械学習が誤判断するような推論対象データ／推論対象物を意図的に作成する
	ポイズニング攻撃	推論時に機械学習が誤判断してしまうように、訓練データに攻撃者の攻撃データを紛れ込ませて訓練させる
訓練済みモデルから情報を盗み取る	モデル抽出攻撃	機械学習の推論処理を何回も正当に行い、攻撃者の手元に訓練済みモデルを複製する
	モデルインバージョン攻撃	機械学習の推論処理を何回も正当に行い、訓練データを攻撃者の手元で復元する
	メンバシップ推測攻撃	機械学習の推論処理を正当に行い、攻撃者の与えたデータが訓練データに含まれるかどうかを推論することで訓練データを推測する

II-3.2. 攻撃による被害について

表 II- 1 に示した攻撃による被害を説明する。

・回避攻撃（敵対的サンプル）

攻撃者によって作成されたデータや物体によって機械学習システムが誤判断する。例えば、自動運転などで、カメラで撮影した道路標識からどの標識であったかを分類するような機械学習システムが存在した場合、道路標識に対してシステムが誤判断するように巧みに計算したテープを貼るなどの攻撃が想定される[II-2]。この標識を撮影した自動運転車は異なる標識と誤分類して事故を引き起こす。

・ポイズニング攻撃

攻撃者が機械学習システムの訓練フェーズに入り、攻撃者が作成したデータを訓練させることができるように攻撃が成功する。これにより、機械学習システムの精度を落としたり、誤判断を起こしたりする恐れがある。また、特定のデータが入力された場合のみ誤判断を起こすような訓練をされる恐れがある。この特定のデータのことはバックドアと呼ばれる。

・モデル抽出攻撃

攻撃者が機械学習システムに何回もアクセスし、攻撃者の手元に攻撃対象のシステムを複製する。これにより、本来のサービス提供者が労力やコストをかけて訓練した機械学習システムを複製され、無料で使用される可能性がある。また、攻撃者が複製したモデルを使ってサービスを開拓する恐れもある。

・モデルインバージョン攻撃

攻撃者が機械学習システムに何回もアクセスし、攻撃者の手元で攻撃対象のシステムの訓練データを復元する。これにより、機械学習システムが訓練の際に使用した訓練データが漏洩し、プライバシーの問題を起こす恐れがある。例えば顔を分類するシステムにおいて、誰の画像を使って訓練したかが漏洩する。

・メンバシップ推測攻撃

攻撃者が機械学習システムにアクセスし、攻撃者が保持しているデータが訓練データに含まれているかどうかを推定する。これにより攻撃者に訓練データの情報が漏洩し、プライバシーの問題を起こす恐れがある。例えば既往歴を扱う機械学習システムにおいて、訓練データに特定の人物のデータが含まれているかを推定することができ、その人物に既往歴があることが分かる。

II-4. 機械学習システムを守るには

この章では II-3 章で説明した機械学習システムへの攻撃を防ぐための戦略、及び、通常の IT セキュリティの取り扱いについて説明する。

II-4.1. 機械学習システムを守る手段

機械学習システムセキュリティガイドライン本編で示されている通り、機械学習特有の攻撃からシステムを守る手段としては以下の 2 種類の手段が存在する。

1. 機械学習システムへの攻撃に対する専用手段による防御
2. 機械学習システムへの攻撃を実施困難にする運用による防御

上記の内、専用手段による防御とは、II-3.1 節で説明した機械学習システム特有の攻撃への専用防御手段のことである。現在幅広く研究され、機械学習システムセキュリティガイドライン本編 I-6 章に記載されるように多くの手法が提案されているが、どの防御手段で守っているかを知っている攻撃者については、防御を回避する攻撃ができてしまうケースがあることも指摘されている。このため、これさえ実施すれば守れるというような確固たる手段は未だ確立されていないのが現状である。このため、専用の防御手段を適用する前に、実施できる攻撃を極力減らしておくのが好ましい。実施できる攻撃を減らす手段としてシステム仕様を適切に設定したり、運用で防御したりする手段がある。例えば敵対的サンプルを生成する攻撃では、攻撃者が何回も推論処理にアクセスすることで攻撃を実現する。そこで、一定期間に推論処理にアクセスできる回数を制限するなどの対応を考えられる。このような防御は、システムに実施できる攻撃が何であるかを知り、攻撃者がその攻撃を実施するために必要な実施条件（前述の例においては、「攻撃者が推論処理へのアクセスを大量に実行でき」、かつ、「攻撃者が推論結果入手でき」、かつ、「攻撃者が機械学習システムデータ入手できる」など）を満たさなくなるようなシステム仕様を採用することで実現する。このため、実施可能な攻撃と、その攻撃の実施可能条件を知ることが重要となる。これらを知るための手段としてセキュリティリスク分析が重要である。

II-4.2. 機械学習システムにおけるセキュリティリスク分析

一般のサイバーセキュリティにおけるセキュリティリスク分析では、保護資産の特定、脅威の抽出、攻撃を実施する手段の分析、攻撃を受けた際の被害の分析などを実施する。このような分析の流れは、例えば IoT 機器に対するものは、[II-3]に詳細にまとめられている。この文書は IoT 機器向けであるが、様々な分野に考え方を応用できると考えられ、本文書でも参考にする。[II-3]によれば、セキュリティリスク分析は以下の流れで実施される。

1. セキュリティリスク分析の対象と守るべき資産の洗い出し

2. データフローの可視化
3. 脅威の洗い出し
4. 脅威を実現する攻撃手法の調査
5. 脅威が実現した場合のリスクの評価

上記の内、1 の分析対象は機械学習システムと決められる。守るべき資産については 3 の脅威の洗い出しと同時に考えることができる。機械学習システムにおける機械学習特有の攻撃による脅威は「システムの誤判断を意図的に起こされる」、「訓練済モデルが漏洩される」、「訓練データが漏洩される」の 3 つに限定されると考えてよい。これによれば、守るべき資産は「システムの正常動作」、「訓練済モデル」、「訓練データ」となるが、実際に 3 つとも守るべきかどうかはシステムに応じて決められる。2 のデータフローの可視化はセキュリティリスク分析におけるデータフローダイアグラム (DFD) に相当すると考えられる。DFD に粒度は細かい方が詳細な分析が可能となるが、AI セキュリティの専門知識を用いずに分析をする 1 次分析としては、典型的には図 II- 1、図 II- 2 のように表すことができる。残る 4、5 については、一般的には AI セキュリティの専門知識を必要とするが、今回は AI 開発者向けの分析手法を目指し、容易に実施できる手段を紹介する。本文書では 4 の脅威を実現する攻撃手法の調査を「脅威分析」、5 の脅威が実現した場合のリスクの評価を「影響分析」、両者を含むリスク分析全体を「セキュリティリスク分析」（あるいは単にリスク分析）と呼ぶこととする。

II-4.3. 通常の IT セキュリティとの関係

機械学習システムセキュリティガイドライン本編 I-1.3.3 節で示した通り、機械学習システムには機械学習システム特有の攻撃以外にも、通常の IT セキュリティ分野の攻撃が実施できる可能性がある。例えば、システムに侵入して機械学習モデルを直接盗んだりする攻撃も想定される。機械学習システムを安全にするには、このような通常の IT セキュリティ分野の攻撃に対する脆弱性と、本ガイドラインで説明した機械学習特有の攻撃の両方から守る必要がある。このうち本ガイドラインでは、機械学習特有の攻撃のみ説明する。

II-5. 機械学習システム開発プロセスにおけるリスク分析

この章では機械学習セキュリティに対する対策を行うための開発プロセス、及び、その問題点を整理し、目指すべき開発プロセスについて説明する。

II-5.1. 機械学習システム特有の攻撃に対するセキュリティを考慮した開発プロセス

II-4章で説明した通り、機械学習システム特有の攻撃からシステムを守るには、リスク分析が必要である。リスク分析とは、前述の脅威分析に加えて、攻撃された際に生じる影響を分析する影響分析を含んでいる。図 II-3に示した通常の機械学習システムにおける機械学習処理部の開発プロセスに対してセキュリティ対応を考慮したプロセスは図 II-4のようになると想定される。




図 II-4. 機械学習システム特有の攻撃に対するセキュリティに対応した
機械学習処理部の開発プロセス

現状、機械学習システム特有の攻撃に対するリスク分析は、機械学習セキュリティの専門家（AIセキュリティ専門家）が実施するのが一般的であると考えられる。AIセキュリティ専門家は、AI開発者からの依頼を受けて、システムにどんなことが起きると問題となるか（どの攻撃から守りたいか、どんな被害が生じると問題となるか）などをAI開発者や顧客からヒアリングしたのちリスク分析を行う。ここで、システムに攻撃が実施可能であるとの結論となった場合には、どのような仕様／運用にすれば守れるかの対応案を検討し、その方法をAI開発者に通知する。通知を受けたAI開発者はシステムを再設計し、PoCからやり直す。あるいは、顧客の要求を満足するとどうしても攻撃ができてしまうという結論となつた場合には顧客とも相談して新たに要求を作り直してから再設計する。しかし、図 II-4で

示した開発プロセスにおいては、AI セキュリティ専門家によるリスク分析によって多くの問題点が発見される可能性があり、リスク分析と再設計を何度も繰り返す可能性がある。このような手戻りは開発効率を下げ、開発コストの増加や納期の遅延を生じる可能性があると考えられる。このためより効率の良い開発プロセスが期待される。この問題を解決するには、現状 AI セキュリティ専門家でないと実施できないリスク分析について、AI 開発者が実施できるようにする必要がある。また、AI セキュリティ専門家そのものの人数も多くはなく、AI セキュリティ専門家が各企業にいるとも限らないため、この点においても AI 開発者自身で分析を行うことが良い解決策になる。

このような AI 開発者自身が行うリスク分析を **AI 開発者向けリスク分析** と呼ぶことにする。AI 開発者向けリスク分析があれば、AI 開発者自らがリスク分析を行って、安全な仕様や運用を導くことができ、再設計を生じたとしても図 II- 4 で示したプロセスほどの多数回の手戻りは生じないと推定する。また、AI セキュリティ専門家のいない企業においてもリスク分析を実施できるようになる（ただし、脆弱性が発見された際には AI セキュリティ専門家への相談は必要となる）。AI 開発者向けリスク分析を開発プロセスに入れた例を図 II- 5 に示す。本ドキュメントでは AI 開発者向けリスク分析を実現するための手段と、著者らが実際に考案した AI 開発者向けリスク分析の一例を紹介する。なお、セキュリティ詳細評価の後で提示された対応案候補に含まれる可能性のある、攻撃検知技術については、別書「攻撃検知技術の概要」を参照されたい。本ドキュメントで紹介する分析手法は一例であり、AI セキュリティ専門家と共同で分析を行う場合などは必ずしも用いなくてもよい。

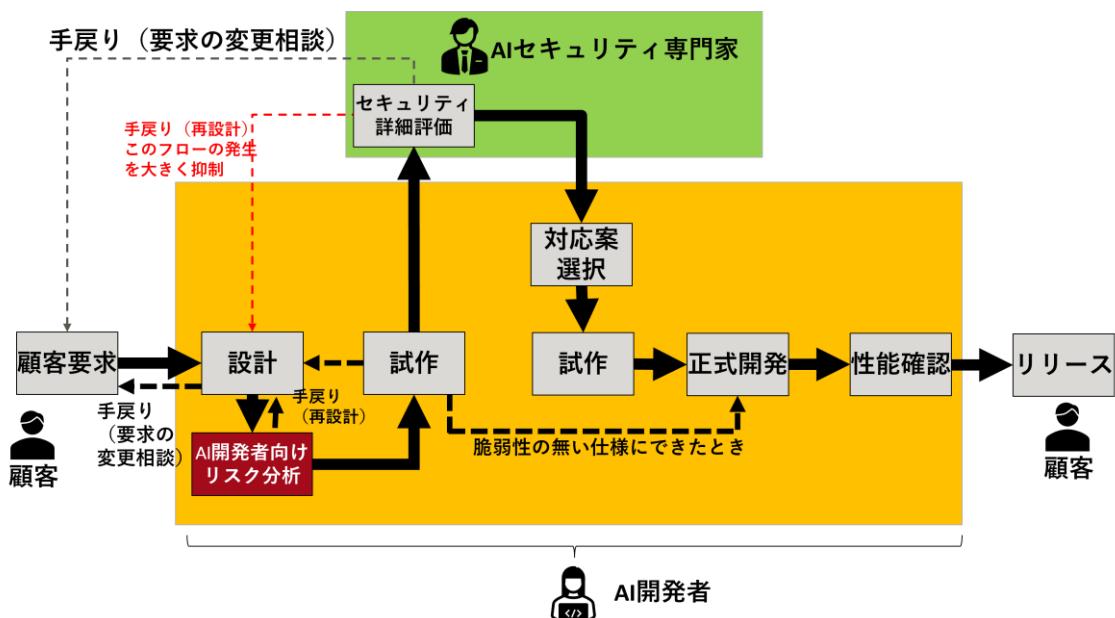


図 II- 5. セキュリティ対策による手戻りを抑制した
機械学習処理部の開発プロセス（目指すべき形）

II-5.2. 機械学習システム向けのリスク分析技術について

機械学習のリスク分析については、AI 開発者と AI セキュリティ専門家が共同で行うことができるような技術が提案されつつある。ENISA は[II-4]にて、AI システムに対する脅威や資産について、ライフサイクルを考慮しながらまとめている。また、脅威モデリングとして、資産の特定や脅威の特定、脆弱性の特定などを含む 5 段階の手法を概要レベルでまとめている。マイクロソフトは[II-5]にて、AI における脅威のモデル化の考え方をまとめている。この中で、AI 開発時に確認すべき項目を質問ベースでまとめている。この質問には AI セキュリティの専門知識が必要なものも多い。このような技術は図 II- 4 や図 II- 5 のセキュリティ専門家の部分に適用可能な技術であると考えられ、AI 開発者と AI セキュリティ専門家が共同で実施するリスク分析としては参考になる。

II-5.3. AI 開発者向けリスク分析

AI 開発者向けのリスク分析では、開発中のシステムに対して、①どのような攻撃が実施できるか、また、②攻撃が実施された際にどのような被害を生じるかを洗い出す必要がある。その後、③として①、②の結果を元に対策を検討する。

一般的なサイバーセキュリティでのリスク分析では、①の結果抽出された攻撃アルゴリズムに対し、それらの攻撃によってどの程度の被害が生じるかを②で分析して③の対策を検討する。機械学習特有のリスク分析を考えた場合、①の実施後に②を検討する際に、攻撃アルゴリズムを用いた結果どのような被害が出るのか、アルゴリズム単位での詳細な専門知識が必要になる。本ドキュメントでは必ずしも専門知識を持っていない可能性のある AI 開発者が実施する手段を目指すため、このままこの方法を用いるのは難しい。そこで、①で抽出した攻撃アルゴリズムに対して被害を分析するのではなく、②では攻撃の種類単位で被害を分析する方法を紹介する。被害の種類は、AI の誤判断、学習済モデルの漏洩、訓練データの漏洩に限定されるため、アルゴリズム単位の知識は必要なく、これらの被害を検討するのであれば比較的容易に分析を行える。そして、これらの被害から、それらを引き起こす攻撃の種類を、専門家によって準備されたテーブルを参照することで見極めて、どの攻撃に対応するべきかを検討・判断する。これにより、専門知識が乏しくてもリスク分析が実施できることが期待できる。

①、②が終わったら、実施可能と判断された攻撃に対してどのような仕様に変更すれば、あるいはどのようなシステム運用をすれば防げるかを③で分析し、再設計への参考情報とする。本ガイドラインでは、①と③を解決する分析技術の一例として、**選択回答式 AI セキュリティリスク問診 (AI リスク問診)** を紹介する。また、②を解決する技術の一例として、**AI 影響分析** を紹介する。

AI リスク問診は、AI セキュリティ専門家が事前に検討した選択式質問に分析者 (AI 開発

者) が回答することで分析を実施する。質問への回答後は、AI セキュリティ専門家が準備したアタックツリーが成立しているかどうかを質問への回答結果から判定する。これによりどの攻撃が実施できるかを明らかにして①を解決する。AI リスク問診では、成立したツリーを不成立にする条件が可視化されるため③も解決できる。②については、実際に攻撃を受けた際にどのような被害が機械学習システムに生じるかを明らかにする分析であり、Failure Mode and Effects Analysis (FMEA)[II-7]などの技術を用いて実施することができる。分析対象を機械学習特有の攻撃に限定することで生じる脅威も限定されるため、どの攻撃が実施できるとどのような被害が生じるかは AI セキュリティの専門知識を有していない分析者でも明らかにするとできると期待できる。本ガイドラインでは実施の一例を紹介する。以降、AI リスク問診と AI 影響分析について詳しく説明する。なお、AI リスク問診と AI 影響分析は、先に影響分析を実施する方が良いと考えられる。なぜなら、AI 影響分析の方が AI リスク問診よりも容易に実施できると考えられるためである。AI 影響分析の結果、攻撃による被害が小さく、対応する必要がないと判断した場合には、より複雑な AI リスク問診による分析を省略でき、分析にかかる手間を削減することができる。影響分析と脅威分析を組み合わせたセキュリティリスク分析のフレームワークは[II-7]に示されており、以下に図示する。




図 II-6. 開発者向けセキュリティリスク分析フレームワーク([II-7])

まず影響分析を実施して、分析対象システムが攻撃された際にどのような最大被害が生じるかを抽出する。その後、その最大被害を引き起こす攻撃の種類が何であるかを特定し、特定した攻撃が実施可能であるかを脅威分析で明らかにする。脅威分析の結果、「攻撃可能」と判断された場合には、それに対する対応を検討する。対応は、その攻撃が実施できなくなるように仕様を変更してもよいし、攻撃検知やモデルの強化などの機械学習特有の対策を施してもよい。

II-6. AI 開発者向け影響分析

この章では AI 開発者向けリスク分析の内の影響分析部分に相当する技術の一例として、AI 影響分析を紹介する。この技術は一例であり、攻撃による被害の種類や大きさを洗い出すことができるのであれば、必ずしもこの技術を使う必要はない。本影響分析は II-5 章で説明した開発プロセスで利用可能なものを目指しているが、必ずしも II-5 章の開発プロセスを前提としておらず、AI セキュリティ専門家ではない分析者、あるいは AI セキュリティ専門家を含めて、機械学習システムの分析を仕様情報から行うことができる技術である。

II-6.1. AI 影響分析

AI 影響分析に求められる要件は以下のとおりである。

1. 機械学習特有の攻撃に対する被害を明らかにできること
2. 機械学習セキュリティの専門知識が無くても容易に分析できること
3. 発生する可能性のある「最大の被害」を見逃さず、分析者による分析結果の差異が少ないこと

1 については、機械学習特有の攻撃により、機械学習の誤判断、訓練済モデルの漏洩、訓練データの漏洩の 3 つの被害を生じる可能性があるためこれらが分析できれば良い。2 については、開発者向けの分析を目指すために必要である。3 については、この分析により攻撃によって被る最大の被害を明らかにして、その後、最大の被害を及ぼす攻撃の種類を特定することで、どの攻撃に対応すべきかどうかを明らかにできる。つまり、この分析は対応を行うべきかどうかを決めるための分析であり、対応要否の判断は最大の被害の情報で行うことから、最大の被害が導出できれば良い。なお、被害の種類と攻撃手法の関係は表 II-2 のようにまとめられる。例えば、影響分析により機械学習の誤判断の被害を大きいと分析された場合には、回避攻撃とポイズニング攻撃が実施可能であるかを脅威分析で見極め、「攻撃可能」と判断された場合に対応をする必要がある。あるいは、重大な判断を行う機械学習システムの場合には、影響分析の結果のみから対応・対策を検討することも想定される。

表 II- 2. 被害の種類と攻撃手法の関係

被害の種類	対応する攻撃手法
機械学習の誤判断	回避攻撃、ポイズニング攻撃
訓練済モデルの漏洩	モデル抽出攻撃
訓練データの漏洩	モデルインバージョン攻撃、メンバシップ推測攻撃

II-6.1.1. 機械学習セキュリティ専門家による事前準備手順

はじめに、機械学習セキュリティの専門家が分析のための分析ワークシートを作成する。分析者は作成されたワークシートを埋めることで分析を行う。このようなワークシートは前述の要件を満たすように作成する必要がある。

・要件を満たすワークシートの設計方針

要件 1 を満たすためには、機械学習特有の攻撃によって生じる被害が導出できれば良い。前述の通り、機械学習特有の攻撃は、機械学習の誤判断、訓練済モデルの漏洩、訓練データの漏洩を引き起こすため、これらが適切に抽出できるようにする必要がある。

要件 2 を満たすためには、誰でも容易に分析できるような仕組みにする必要がある。分析の難易度が低いことで、誰もが同じような結果が得られる分析になると期待できる。具体的な手段としては、機械学習の誤判断を抽出するには、まずその機械学習システムでやりたいことや正常動作を定義し、その動作が達成できなくなるとどうなるかを導けばよい。これには FMEA のように故障モードを定義したり、誰が、なぜ、どこで、どうして、誰に（何に）、どうなる、などのガイドワードを用いたりして、システムが誤判断するとはどういうことなのか、それによる何が起きるのかを導出できるようなワークシートにする必要がある。訓練済モデルの漏洩と訓練データの漏洩については、「漏洩しないこと」が正常動作であり、「漏洩」が故障モードであるため、機械学習の誤判断と異なり、故障モードは既に導出できていると言える。よって故障モードは導出せず、ガイドワードによる分析でだけでよい。このような容易に実施できる分析手段を準備することで、被害の見逃しも減り、要件 3 も満たすことができると考えられる。このような考え方で作成した影響分析の一例は [II-7] に記載されており、次章にて紹介する。

II-7. AI 影響分析の実現例

この章では、II-6 章にて説明した開発者向けの影響分析を実現した一例を紹介する。

II-7.1. 影響分析ワークシート

II-6 章にて説明した影響分析手法を Microsoft Excel 形式のワークシートとして実装した。これは一実現例であり、攻撃による最大被害が導出できるのであれば、必ずしもこのワークシートを用いなくてもよい。本ワークシートは I から IV-2 までのシートから構成されている。シート 1 の画面イメージの一部を図 II-7 に示す。このシートは分析の進め方が説明されている。

自動保存 ○ 検索 (Alt+Q) 検索 (Alt+Q) Yajima, Jun/矢場 純 フォント 大文字 小文字 リンク 共有

ファイル ホーム 挿入 ページレイアウト 数式 データ 校間 表示 ヘルプ

A1

AIシステムに対するAI特有の攻撃の影響分析ワークシート Copyright ©2023 富士通株式会社

【本分析ワークシート（通常、AI被害分析）について】

AIには従来のサイバーアクションとは異なるAI特有の攻撃があります。

AI特有の攻撃にはAIの誤論を間違えさせる「誤判断を起こさせる攻撃」と、訓練済モデルや訓練データを含む「情報漏洩を起こす攻撃」があります。

本分析は、分析対象のAIシステムがAI特有の攻撃を受けた際に想定される被害や影響を、分析者が導出・検討することを助けます。

導出して明らかになった被害や影響を検討し、対処を行うかどうかを判断してください。

本分析は質問に回答し、テーブルに整理することで、分析を進めます。

本分析で想定するAIシステムの構成を図1に示します。

攻撃者は攻撃により、AIの誤判断を起こさせたり、訓練済モデルを盗んだり、訓練データを盗んだりする可能性があります。

これらの攻撃による被害の大きさや影響を本ツールを使って導出し、対処をどうかを判断してください。

実際に攻撃が成功するかどうかについては、脅威分析ツール（通常、AIリスク診断）を用いて分析することで明らかになります。

両ツールを利用し、適切なセキュリティ確保を行いましょう。

図1. AIシステムで狙われる部分

訓練時

訓練データ → 訓練 → 訓練済みモデル

推論時

推論対象データ → 推論 → 推論結果

攻撃者

盗みたい

間違えさせたい

I. 説明 II. ヒアリングシート III. 影響分析のための準備 IV-1. AIの誤判断被害の ...

図 II-7. 影響分析ワークシートのシート I のイメージ

機械学習システムセキュリティガイドライン Part II. 「リスク分析編」

ワークシートのシート II の画面イメージの一部を図 II-8 に示す。シート II では AI システムの仕様に関する情報を記入する。仕様情報は、AI システムが達成したい目的、訓練者、訓練データの秘密度合い、AI システムに関連する人々などである。これらの情報を元に、分析に必要な情報をシート III にて抽出する。

The screenshot shows the 'Impact Analysis Worksheet' (II-8) in Microsoft Excel. The worksheet is organized into several sections:

- Section 1: AI System Details** (Rows 5-7)
 - Row 5: HS1. AI システムの名称を以下に記入してください
 - Row 6: 名称 (Cell A6 is selected)
 - Row 7: HS2. AI システムの目的 (タスク) を以下に記入してください
 - Example: 自動運転における標識識別AIの場合: 入力された道路標識画像を分類する
 - Medical AI の場合: レントゲン画像から病名を推測 (分類) する
 - Plant Control AI の場合: センサから得られた情報を元に適切な酸素供給量を推定する
 - Handwriting Recognition AI の場合: 手書きされた文字の種類を分類する
- Section 2: Training Data (Rows 11-12)**
 - Row 11: HS3. 訓練済モデルについてのヒアリング
 - Row 12: HM1. 訓練済モデルを学習させた人・会社について記入してください。
 - Example: 訓練が複数の段階に分かれている場合には、両方記入してください。
 - Example: 自動運転における標識識別AIの場合: 自社で訓練
 - Medical AI の場合: 訓練されたAIシステムを購入し、自医院のデータでファインチューニング (自社開発の場合: 自社で訓練)
 - Plant Control AI の場合: 自社で訓練
 - Handwriting Recognition AI の場合: 自社で訓練
- Section 3: Training Subjects (Rows 13-14)**
 - Row 13: HM2. 訓練済モデルの秘密度合いを記入してください (重要機密、秘密、秘密ではない、誰でも入手可能等)
 - Example: 自動運転における標識識別AIの場合: 重要機密
 - Medical AI の場合: ベースのモデルは購入すれば誰でも入手可能。ファインチューニング部分は秘密 (自社開発の場合: 密密)
 - Plant Control AI の場合: 重要機密

At the bottom of the worksheet, there are tabs for I. 説明, II. ヒアリングシート (selected), III. 影響分析のための準備, IV-1. AIの誤判断被害の ..., and other buttons.

図 II-8. 影響分析ワークシートのシート II のイメージ

機械学習システムセキュリティガイドライン Part II. 「リスク分析編」

シート III の画面イメージの一部を図 II- 9 に示す。このシートでは、FMEA の考え方に基づき、シート II で記入した AI システムで達成したいことを反転して、故障モードを導出する。また、AI が誤判断したり、情報漏洩が発生したりしたと想定した場合の想定被害者の抽出も行う。

The screenshot shows a Microsoft Excel spreadsheet titled "影響分析v0.80.xlsx - 読み取り専用". The active sheet is "III. 影響分析のための準備". The content includes:

- Row 1:** 自動保存, 検索 (Alt+Q), ユーザー名: Yajima, Jun/矢島 純.
- Row 2:** ファイル, ホーム, 挿入, ページレイアウト, 数式, データ, 校閲, 表示, ヘルプ.
- Row 3:** A1 単位, フィルタ, 印刷範囲.
- Row 4:** 1 行目, A1 セルが選択されている.
- Row 5:** 2 行目, セル内に「影響分析準備シート」と入力されている.
- Row 6:** 3 行目, セル内に「AI特有の攻撃により、「AIの誤判断」、「モデルの漏洩」、「訓練データの漏洩」が起きる可能性があります。これらの被害を分析するにあたり、「ヒアリングシート」での入力情報を整理します。」と記載.
- Row 7:** 4 行目, セル内に「AIの誤判断被害の分析に関する整理」と記載.
- Row 8:** 5 行目, セル内に「タスクを反転することでAIの誤判断の内容を明らかにします」と記載.
- Row 9:** 6 行目, セル内に「ヒアリングシートHS2に記入したAIシステムの目的（タスク）について、動詞を「できない」の形に否定すること（タスク）が達成できないケースがどういうものかをD11欄に記入してください」と記載.
- Row 10:** 7 行目, セル内に「目的（タスク）（HS2）」と記載.
- Row 11:** 8 行目, セル内に「目的（タスク）を反転し、「できない」の形で否定形を記入してください」と記載.
- Row 12:** 9 行目, セル内に「例. 自動運転における標識識別AIの場合：入力された道路標識画像を分類する→入力された道路標識画像を分類できません。医療AIの場合：レントゲン画像から病名を推測（分類）する→レントゲン画像から病名を推測（分類）できません。プラント制御AIの場合：センサから得られた情報を元に適切な酸素供給量を推定する→センサから得られた情報手書き文字認識AIの場合：手書きされた文字の種類を分類する→手書きされた文字の種類を分類できません」と記載.
- Row 13:** 10 行目, セル内に「目的（タスク）の反転」と記載.
- Row 14:** 11 行目, セル内に「上の欄（D11）の事象が、AIの誤判断が起きたときに発生する可能性があります」と記載.
- Row 15:** 12 行目, セル内に「AIの誤判断によって想定される被害者を明らかにします」と記載.
- Row 16:** 13 行目, セル内に「ヒアリングシートHS1に記入した「AIに関連する人々」のうち、AIの誤判断により影響を受ける可能性のある人々です。AIの誤動作により影響を受ける人々をHR1の人々の中から全て選んでD17欄に記入してください」と記載.
- Row 17:** 14 行目, セル内に「記入の際には、AIの誤動作が起きたと仮定した際に影響を受ける人々をD16欄から全て選んで記入してください。影響を受ける人々の典型としては、ユーザー（AIにデータを与える人々）、システムの影響を受ける第三者、運用者（タ）、運営者、サービス提供者、運営会社などがあります。
- Row 18:** 15 行目, セル内に「例. 自動運転における標識識別AIの場合：歩行者（第三者）、ドライバー、サービス運営会社
医療AIの場合：患者、医者、病院、サービス販売者（チーニング業者）
プラント制御AIの場合：プラント労働者、プラント運営会社
手書き文字認識AIの場合：文字入力者、サービス運営会社」と記載.
- Row 19:** 16 行目, セル内に「AIに関連する人々（HR1）」と記載.
- Row 20:** 17 行目, セル内に「AIの誤判断の想定被害者」と記載.

図 II- 9. 影響分析ワークシートのシート III のイメージ

機械学習システムセキュリティガイドライン Part II. 「リスク分析編」

シート IV-1 はシート II、シート III で集めた情報を元に、AI の誤判断被害を分析するシートである。シート IV-1 の画面イメージの一部を図 II- 10 に示す。誰が、なぜ、どこで、どうして、誰に（何に）、どうなる、「どうなる」により生じる具体的な影響、引き起こされる被害、対処必要性、の順にシートに記入していく。これらの項目の多くは機械学習に限定することで固定されており、実質的には水色の欄を考えるのみでよい（黄色欄は別枠から複写するだけでよい）。記入に際しては本シートに書いてある説明文を参考にするとよい。対処必要性は、その被害が生じたと仮定した場合に対処が必要かどうかを、重大度に応じて、大、中、小、無で分析者の主観で判断する。このレベルに応じて対処の優先度が明らかになる。

行番号	誰が	なぜ	どこで	どうして	誰に (何に)	どうなる	「どうなる」により生じる具体的な影響	引き起こされる被害
10	AIによる誤判断被害を以下のように記入してください。漏れなければ行き飛ばしてください。							
11	誤判断のコードを記入してください。							
12	誰が：攻撃者（固定）							
13	なぜ：攻撃をすること（固定）							
14	どこで：AIシステムの名前（D5欄）を記入してください							
15	どうして：AIの誤判断を起こさせて（固定）							
16	誰に（何に）：想定被害者（D7欄）から一人を選んで記入してください（全ての想定被害者候補を費用1箇所ずつ）							
17	その他の想定被害者（D8欄）から一つを選んで記入してください（全ての想定被害者候補を費用1箇所ずつ）							
18	どうなる：想定されるAIの誤判断（D9欄）根を記入してください							
19	「どうなる」により生じる具体的な影響：「どうなる」の根の構造、何が起きるか、AIシステムに生じる具体的な影響（異常動作等）を記入してください。							
20	記入例のコードを参考に、左の欄の内見書きをして記入してください。特に「誰に（何に）」の欄に注意し、起きることを想像して記入してください。							
21	起きることには、「誰に（何に）」「どうなる」に対して起きる被害のうち、最大のものを判定して記入してください。							
22	誤判断の内容、人の技術、人間の技術、精神的技術（物理的な問題も含む）、その他の被害（含めを限れない被害等）の範囲それぞれについて記入してください。							
23	それに加えて、サービス提供者が被害を受け可能か否か等のケースにおいては、サービス提供者の組織技術、その他の被害についても記入してください。							
24	例えば、自動運転の機器がAIで想定被害者や歩行者の動き、人間甲斐を起こす（人間の技術）、							
25	保護の状況によっては組織技術用語（組織技術）で記入され歩行者（組織技術）、甲斐を起こし人間甲斐を起こす（精神的技術）、							
26	（他の被害）、サービス提供者が組織技術（サービス提供者の組織技術）、なし（サービス提供者の他の被害）							
27	また、分析対象のAIは既存のAIガートリVにあります。そちらも参考にして記入してください。							
28	対処必要性：他の側の被害が起きたと仮定した場合には、対処する必要があるか（大、「中」、「小」、「無」）で記入してください。							
29	実際は対応がでて、その被害が生じるかどうかは専門家で明らかになります。この分析では被害だけを見て対処必要性を判断してください。							
30								
31								
32								
33	AIの誤判断を起こさせて							
34								
35								
36								
37	AIの誤判断を起こさせて							
38								
39								
40	AIの誤判断を起こさせて							

図 II- 10. 影響分析ワークシートのシート IV-1 のイメージ

機械学習システムセキュリティガイドライン Part II. 「リスク分析編」

シート IV-2 はシート IV-1 の訓練済モデル漏洩、訓練データ漏洩を明らかにするシートに相当する。シート IV-2 の画面イメージの一部を図 II- 11 に示す。シート IV-1 と同様に、シート II、シート III で集めた情報を元に、被害を分析する。誰が、なぜ、どこで、どうして、誰に、どうなる、引き起こされる被害、対処必要性、の順にシートに記入していく。このシートも、多くの項目が機械学習に限定することで固定されており、実質的には水色の欄を考えるのみでよい（黄色欄は別枠から複写するだけでよい）。AI の誤判断よりも被害が具体的であるため、検討すべき項目が少ない。記入に際しては本シートに書いてある説明文を参考にするとよい。対処必要性は、その被害が生じたと仮定した場合に対処が必要かどうかを、重大度に応じて、大、中、小、無で分析者の主観で判断する。このレベルに応じて対処の優先度が明らかになる。

D	E	F	G	H	I	J	
20	どうなる：訓練済モデルを盗まれる（固定）						
21	引き起こされる被害：「どうなる」の欄の種類、どのような被害が起きるかを想像して記入してください。 金銭被害、その他の被害の組合で記入してください。例えば、モデルを資料で利用され、モデル訓練の工数が無駄になる、モデルを使ってサービス展開される等になります。 また、分析対象のAIに相似のAIがシートVIにあれば、そちらも参考にして記入してください。						
22	対処必要性：左の欄の被害が起きると仮定した場合に、対処する必要がどれ位あるかを「大」「中」「小」「無」で記入してください。 訓練済モデルの私密度（D7欄）も考慮してください。 実際に攻撃ができる、その被害が生じるかどうかは専門分析で明らかになります。この分析では被害だけを見て対処必要性を判断してください。						
23							
24	誰が	なぜ	どこで	どうして	直に	どうなる	引き起こされる被害 （金銭被害面） （その他の被害面）
25	攻撃者	攻撃をすることで		訓練済モデルを漏洩（専取）して		訓練済モデルを盗まれる	（金銭被害面） （その他の被害面）
26							
27	攻撃者	攻撃をすることで		訓練済モデルを漏洩（専取）して		訓練済モデルを盗まれる	（金銭被害面） （その他の被害面）
28							
29	攻撃者	攻撃をすることで		訓練済モデルを漏洩（専取）して		訓練済モデルを盗まれる	（金銭被害面） （その他の被害面）
30							
31	攻撃者	攻撃をすることで		訓練済モデルを漏洩（専取）して		訓練済モデルを盗まれる	（金銭被害面） （その他の被害面）
32							
33	攻撃者	攻撃をすることで		訓練済モデルを漏洩（専取）して		訓練済モデルを盗まれる	（金銭被害面） （その他の被害面）
34							
35	攻撃者	攻撃をすることで		訓練済モデルを漏洩（専取）して		訓練済モデルを盗まれる	（金銭被害面） （その他の被害面）
36							
37							
38							
39							
40	記入例のテーブルを参考は以下の項目を記入してください。足りなければ行を追加してください。						
41	誰が：攻撃者（固定）						
42	なぜ：攻撃をすることで（固定）						
43	どこで：AIシステムの名前（D9欄）を記入してください						
44	どうして：訓練データを漏洩（専取）して（固定）						
45	直に（何に）：想定被害者（D8欄）から一人を選んで記入してください（全ての想定被害者候補を最低1箇ずつ）						
46	どうなる：訓練データを盗まれる（固定）						
47	引き起こされる被害：「どうなる」の欄の種類、どのような被害が起きるかを想像して記入してください。 金銭被害、精神的被害、その他の被害の組合で記入してください。例えば、データ提供会社に損害賠償を請求される（金銭的被害）、プライバシーの被害を生じる（精神的被害）等になります。 また、分析対象のAIに相似のAIがシートVIにあれば、そちらも参考にして記入してください。						
48	対処必要性：左の欄の被害が起きると仮定した場合に、対処する必要がどれ位あるかを「大」「中」「小」「無」で記入してください。 訓練データの入手元（D9欄）、公開度（D10欄）も考慮してください。 実際に攻撃ができる、その被害が生じるかどうかは専門分析で明らかになります。この分析では被害だけを見て対処必要性を判断してください						
49							
50	誰が	なぜ	どこで	どうして	直に	どうなる	引き起こされる被害 （金銭被害面） （精神的被害面） （その他の被害面）
51							
52	攻撃者	攻撃をすることで		訓練データを漏洩（専取）して		訓練データを盗まれる	（金銭被害面） （精神的被害面） （その他の被害面）
53							

図 II- 11. 影響分析ワークシートのシート IV-2 のイメージ

II-8. AI 開発者向け脅威分析

この章では AI 開発者向けリスク分析の内の脅威分析部分に相当する技術として、選択回答式 AI セキュリティリスク問診技術（AI リスク問診）を紹介する。この技術は一例であり、どのような攻撃が実施できるのかを見出すことができるのであれば、必ずしもこの技術を使う必要はない。本脅威分析も影響分析と同様に、II-5 章で説明した開発プロセスで利用可能なものを目指しているが、必ずしも II-5 章の開発プロセスを前提としておらず、AI セキュリティ専門家ではない分析者、あるいは AI セキュリティ専門家を含めて、機械学習システムの分析を仕様情報から行うことができる技術である。

II-8.1. 選択回答式 AI セキュリティリスク問診（AI リスク問診）

AI リスク問診に求められる要件は以下のとおりである。

1. 機械学習特有の攻撃について、どの攻撃がシステムに実施できるかを明らかにできること
2. 機械学習セキュリティの専門知識を持たない AI 開発者が分析できること
3. 誰が分析してもほぼ同じ結果になること
4. 分析結果の納得性が高いこと

上記要件を満たす技術として、アタックツリーを用いた分析手法[II-8]を紹介する。この技術は専門家が事前にアタックツリーを抽出しておき、抽出したツリーが成立するかどうかを分析者自らが分析する。専門家による事前準備を完了すれば、分析自体は AI セキュリティの専門知識を持たない可能性のある AI 開発者が実施することが可能である。本分析では結果がツリー形式で分かるため、結果の理解がしやすくなっている。以下、手順を詳細に説明する。筆者らが準備したアタックツリーや質問等の一例は II-9 章に記載する。それを使って分析した例については II-10 章に記載する。

II-8.1.1. 機械学習セキュリティ専門家による事前準備手順

はじめに、機械学習セキュリティの専門家が分析のための準備をする。この準備は 1 回だけ行えばよい。

II-8.1.1.1. アタックツリーと攻撃実施可能条件の抽出

機械学習システム特有の攻撃についてのアタックツリーを構成するフェーズであり、AI セキュリティ専門家が実施する。アタックツリーは一般の IT セキュリティ分野で利用されている分析技術の一種であり、生じる脅威をトップノードとして、その脅威が発生しうる条件をツリー構造で階層的に抽出したものである。ツリー表現は自由度が高いため、一般のセキュリティにおいてはシステム仕様が定義される前にアタックツリーを事前構成しておくことは困難である。しかし機械学習システムに限定すれば、実施可能な攻撃種や生じうる被害が限定されるため、システムの仕様が定まる前にアタックツリーを構成しておくことが

できる。一般的に機械学習システムへの攻撃は、一つの攻撃に対して複数の攻撃シナリオ（攻撃アルゴリズム）が存在する。ツリーを構成する際には、分析対象とする攻撃シナリオを定め、その攻撃シナリオを実施可能な条件を抽出してノードに記述する。どのシナリオを分析対象とするかは分析の粒度によって定めるが、代表的なものからツリー化していくのが好ましい。攻撃実施が可能となる条件は、論文などを参考に定める。構成したツリーの一部の例を図 II- 12 に示す。この例は回避攻撃（敵対的サンプル）に関するものである。回避攻撃（敵対的サンプル）を実施するためのシナリオを 4 つ準備している（図の左側）。いずれかのシナリオが成立すると攻撃実施可能という判断となる。図の右側は回避攻撃（敵対的サンプル）の攻撃シナリオ A1 の例である。ツリーの左側と右側が同時に成立するときに攻撃シナリオ A1 は実施可能（TRUE）となる。左側の条件は、「条件 6-2 または（条件 2-2 かつ、条件 3-1）」が成立した時に TRUE となる。右側の条件は、「条件 4-2 または条件 7-1」が成立した時に TRUE となる。このような各ノードに書かれている条件は攻撃実施可能条件と呼ばれる。




図 II- 12. 構成したアタックツリー（の一部）の例

II-8.1.1.2. 質問群の準備

アタックツリーの構成と攻撃実施可能条件群の抽出が完了したら、システム仕様が与えられたときに、そのシステムが攻撃実施可能条件を満たしているかどうかを判定するための質問群を作成する。この処理も AI セキュリティ専門家が事前に行う。分析者は AI 開発者を想定しており、必ずしも機械学習セキュリティの専門家ではないと考えられるため。質問はなるべく平易に、かつ、仕様に関する質問とした方が分析者は回答しやすい。具体例な

ども提示して分析者に理解しやすい質問を作るべきである。以下に質問の例を示す。想定攻撃者については後で説明する。

例：

質問 類似データセットの入手に関する質問

「AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？」

(ア) 類似データ 1 個とは AI が処理する最小単位のデータの集まりです。テーブルデータなら 1 行、画像なら 1 枚です。

Yes の例：顔識別 AI

想定攻撃者：利用者

一般的な顔の画像データセットを得ることができます

Yes の例：給与予測 AI

想定攻撃者：第三者

推論に使用するデータの種類（年齢、住所等）と推論対象のデータの種類（給与）が分かっていて、かつ、推論対象のデータセットとほぼ同一の分布のデータセットが入手できる場合

II-8.1.1.3. 攻撃実施可能条件の満足状況の判定用テーブルの準備

II-8.1.1.2 節で準備した質問の回答の結果を元に、II-8.1.1.1 節で抽出した攻撃実施可能条件（アタックツリーのノードに記載されている条件）を満足しているかどうかを判定するためのテーブルを準備する。例えば表 II- 3 のようなテーブルを準備する。このテーブルには、各条件が TRUE だったときに、それを FALSE にするためのシステム要件も記載しておく。FALSE にするシステム要件は対応策の検討で利用する。

表 II- 3. 攻撃実施可能条件の満足状況を判定するテーブルの例

条件の例	TRUEにする条件	判定結果	FALSEにするための対応策
条件1-1 訓練処理の自由な実行が可能	質問1-1Aまたは1-1BがYes	TRUE or FALSE ? (埋める)	管理者など、適かつ必要最小限の人のみ訓練処理が実行できるようにする
条件2-1 推論処理を1回以上実行可能	質問2-1Aまたは2-1BがYes	...	想定攻撃者が推論処理を実行できないように設定する
条件2-2 推論処理を1000回以上実行可能	質問2-2Aまたは2-2BがYes		想定攻撃者がデータ1,000個以上に対して推論処理を実行できないように設定する
条件2-3 推論処理を10000回以上実行可能	質問2-3Aまたは2-3BがYes		想定攻撃者がデータ10,000個以上に対して推論処理を実行できないように設定する
条件2-4 推論処理を1000000回以上実行可能	質問2-4Aまたは2-4BがYes		想定攻撃者がデータ1,000,000個以上に対して推論処理を実行できないように設定する
条件3-1 推論結果入手可能	質問3-1または3-2がYes		判定結果を適かつ必要最小限の人のみに提示するようにする
条件3-2 確信度入手可能	質問3-2がYes		判定結果の確信度を適かつ必要最小限の人のみに提示するようにする
続く	続く		

II-8.1.2. 分析者による分析手順

分析者が分析を行う手順を以下に示す。この手順は II-8.1.1 節で示した準備ができていれば何回も繰り返して実施できる。

II-8.1.2.1. 分析対象システムの仕様と想定攻撃者の明確化

AI セキュリティ専門家が準備した質問に答えるための基礎となる資料として、分析者は分析対象システムの仕様を極力詳しく記述した定義資料（AI のタスク、訓練処理の実施者／実施方法／データ入力方法、推論処理の実施者／実施方法／データ入力方法、提示する出力内容／提示方法／提示先などの情報が書かれた資料）を準備する。この定義資料には、機械学習システムの出力結果を使用者に見せるか？一定の時間当たり何個のデータのクエリを許すか？システムのデータを公開するか？などの情報が含まれる。

また、分析の際に想定する攻撃者（想定攻撃者）を誰にするかも決める。分析の段階では想定攻撃者の能力を考慮して行うことになり、想定攻撃者を誰に想定するかによって分析結果に影響を受ける。従って想定攻撃者を適切に選定・設定することは極めて重要である。想定攻撃者は、システムにデータを提供する人などシステムと関連性が比較的低い人物を想定すると外部からの攻撃者の想定になり、管理者など関連性の高い人物を想定すると内部犯による攻撃者を想定することとなる。適切な想定攻撃者としては、最低限以下の人たちを想定する必要がある。

- ① AI 開発者（内部犯を想定するとき）
- ② 機械学習システムの管理者（内部犯を想定するとき）
- ③ 機械学習システムのエンドユーザー
- ④ 機械学習システムにデータが利用される人（必ずしもユーザとは限らない）

II-8.1.2.2. 質問群への回答

仕様の記述と想定攻撃者の設定が完了したら、AI セキュリティ専門家が準備した質問群に Yes/No で回答する。II-8.1.1.2 節で示したような質問群が準備されている。質問群全体の一例は II-9 章に例示する。

II-8.1.2.3. 攻撃実施可能条件の成立状況の確認

質問への回答を元に、各攻撃シナリオに相当するツリーのノード部分に記載されている攻撃実施可能条件を満たしているか (TRUE/FALSE) を判定する。これは II-8.1.1.3 節で示したような判定用のテーブルを準備し、対応する質問の回答状況から一意に定めることができる。判定用のテーブルの一例は II-9 章に例示する。

II-8.1.2.4. アタックツリーの成立状況の確認

判定用のテーブルを元に判定した攻撃実施可能条件を満たしているかの情報 (TRUE/FALSE) を、アタックツリーのノードに埋める。これにより各攻撃シナリオが成立するか、あるいは、アタックツリーそのものが成立しているかどうかが判断できる。この作業の例を II-10 章に例示する。

II-8.1.2.5. 対策の検討

成立したアタックツリーについては、想定攻撃者によってその攻撃が実施できることを示唆している。このフェーズでは想定攻撃者による攻撃を防ぐための対策を検討する。具体的には成立しているアタックツリーの構造に応じて、各ノードに記載されている攻撃実施可能条件を FALSE にするための仕様変更を検討する。検討の例を図 II-13 に示す。この例では回避攻撃（敵対的サンプル）の攻撃シナリオ A1 が成立してしまっている。図の右側に記載されている攻撃シナリオのツリーを見ると、条件 2-2 を満たさないように機械学習システムの仕様を変更すれば、攻撃は実施しにくくなる。具体的には想定攻撃者による推論処理の実行回数を制限して一定期間に 1000 回未満にするという対応となる。ただし攻撃者が結託する可能性を考慮する場合には、全ユーザにおいて一定期間に推論処理を実行できる回数を 1000 回未満にする必要がある。一定期間とは、攻撃を防ぎたい期間であり、例えば製品の寿命までの期間などである。AI 開発者はこの条件を満たさなくするような仕様変更が実施できるかどうかを検討する。具体的にはアタックツリーのどの葉を不成立 (FALSE) にする (≒仕様変更する) にするかを検討した上で、表 II-3 で例示した判定用テーブルの「FALSE にするための対応策」の欄に記載された対応策を参考に、葉の条件を FALSE にする仕様変更ができるかどうかを検討する。仕様変更ができないと判断した場合には、別の条件を不成立にすることを検討する。あるいは、機械学習特有の攻撃に対する専用の対策を導入することを AI セキュリティ専門家に相談する。

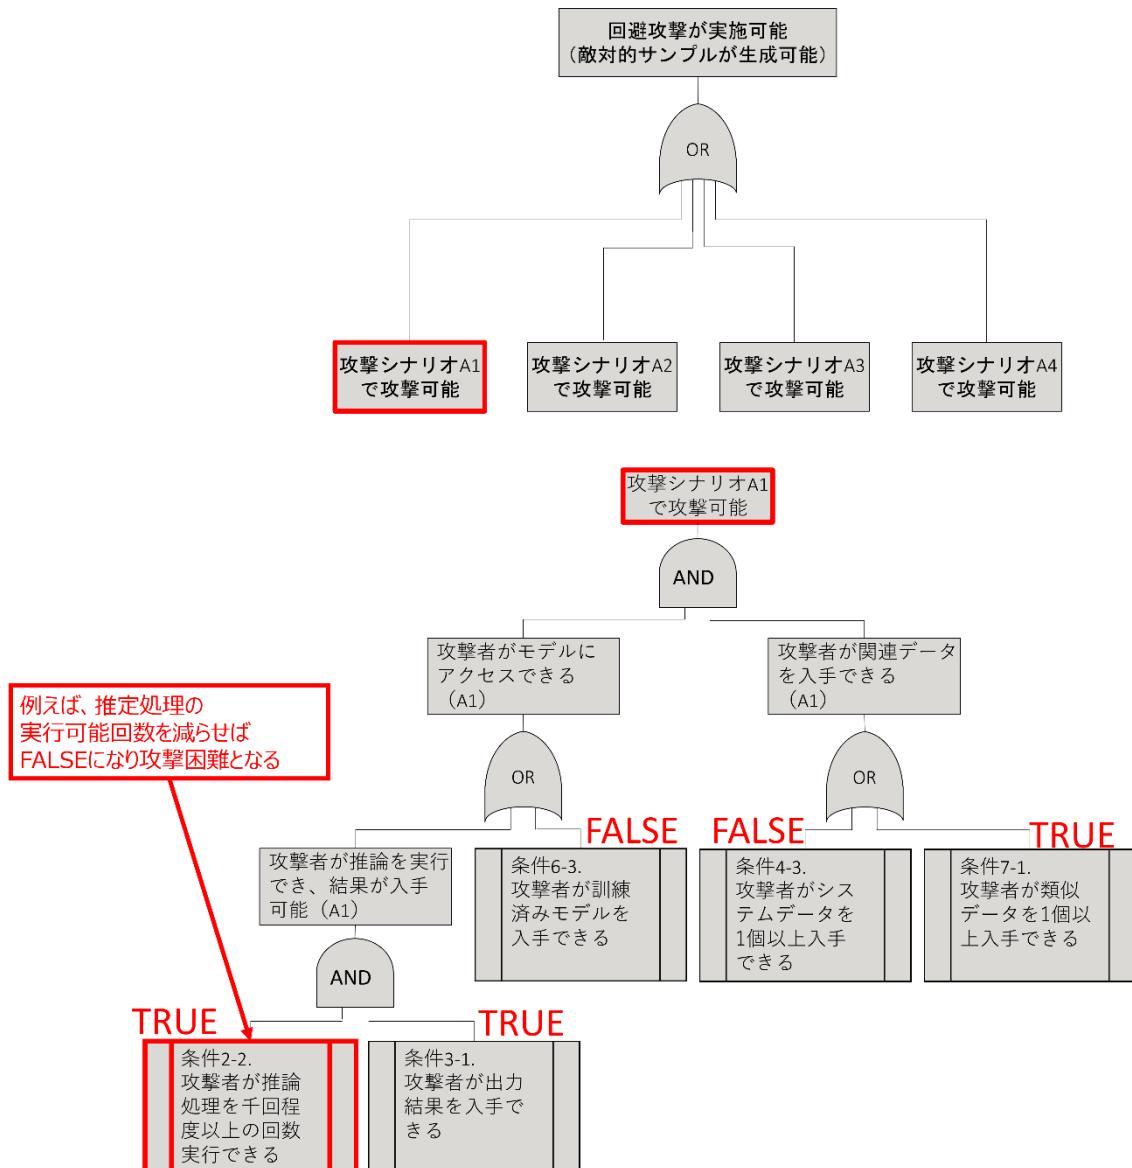


図 II- 13. 対策の検討例

II-9.AI リスク問診の実現例

この章では II-6 章で説明した AI 開発者向けリスク分析の実現例について紹介する。

II-9.1. 注意事項

[II-9]と[II-10]では、II-6 章で構築方法を説明した AI リスク問診についての実現例が示されている。[II-9]と[II-10]では、回避攻撃（敵対的サンプル）、ポイズニング攻撃、モデル抽出攻撃、モデルインバージョン攻撃のアタックツリーが掲載されている。本ガイドラインではこれに加えてメンバシップ推測攻撃についてのアタックツリーも記載するとともに、質問文等をより理解しやすいと思われる形式にしている。この実現例では各攻撃について代表的な攻撃アルゴリズムをシナリオとして定義し、アタックツリーとして抽出している。ただし 2022 年 3 月時点での実現例の一つであり、必ずしも学会等で議論されている全ての攻撃シナリオが網羅されているわけではない。今後攻撃や対策の進化により、見直される可能性／必要性があることに留意されたい。

II-9.2. アタックツリーと攻撃実施可能条件

[II-9] と [II-10] で記載されているアタックツリーとツリーの葉に相当する攻撃実施可能条件を以下に掲載する。各攻撃シナリオがどのような観点で構成されているかを考察した結果を表 II- 4 に示す。A：回避攻撃（敵対的サンプル）、P：ポイズニング攻撃、X：モデル抽出攻撃、I：モデルインバージョン攻撃、M：メンバシップ推測攻撃である。

表 II- 4. 各アタックツリーにおける攻撃シナリオの観点

攻撃シナリオ	アタックツリー構築の観点
A1	ブラックボックス攻撃を想定した基本的な攻撃の実施条件
A2	ホワイトボックス攻撃、及び、モデル抽出攻撃よりも簡易的なモデル複製技術を利用した攻撃の実施条件
A3	モデル抽出攻撃を利用した攻撃の実施条件
A4	ポイズニング攻撃を利用した攻撃の実施条件
P1	ポイズニング攻撃の基本的な実施条件
P2	外部や内部からのモデルを再利用した際に、モデル内部にバックドアが入っていた場合の攻撃実施条件
P3	モデル抽出攻撃を利用した攻撃の実施条件
X1	データフリー系のモデル抽出攻撃の実施条件
X2	代表的なモデル抽出攻撃[II-11]の実施条件
X3	代表的なモデル抽出攻撃[II-12]の実施条件
X4	扱うデータがテーブルデータの際のモデル抽出攻撃の実施条件
X5	扱うデータがテーブルデータ以外（画像等）の際のモデル抽出攻撃の実

	施条件
X6	そもそもモデルを攻撃者が入手できるときの攻撃実施条件
I1	モデルインバージョン攻撃の基本的な実施条件
I2	モデルインバージョン攻撃の基本的な実施条件（勾配情報が入手できるとき）
I3	そもそも訓練データを攻撃者が入手できるときの攻撃実施条件
M1	代表的なメンバシップ推測攻撃[II-13]のその 1
M2	代表的なメンバシップ推測攻撃[II-13]のその 2
M3	代表的なメンバシップ推測攻撃[II-13]のその 3
M4	代表的なメンバシップ推測攻撃[II-14]
M5	代表的なメンバシップ推測攻撃[II-15]
M6	代表的なメンバシップ推測攻撃[II-16]
M7	代表的なメンバシップ推測攻撃[II-17]
M8	そもそも訓練データを攻撃者が入手できるときの攻撃実施条件

II-9.2.1. 回避攻撃（敵対的サンプル）のアタックツリーと攻撃実施好条件

回避攻撃（敵対的サンプル）についてのアタックツリーと攻撃実施可能条件は以下の通り抽出されている。

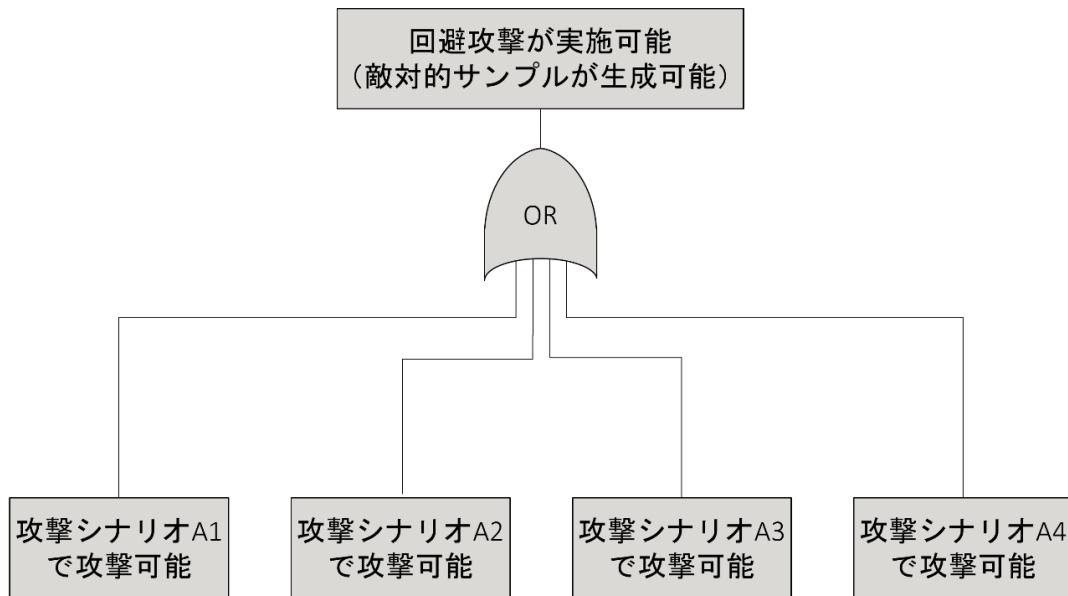


図 II- 14. 回避攻撃（敵対的サンプル）のアタックツリー（上位部分）




図 II- 15. 回避攻撃（敵対的サンプル）の攻撃シナリオ A1 の
アタックツリーと攻撃実施可能条件

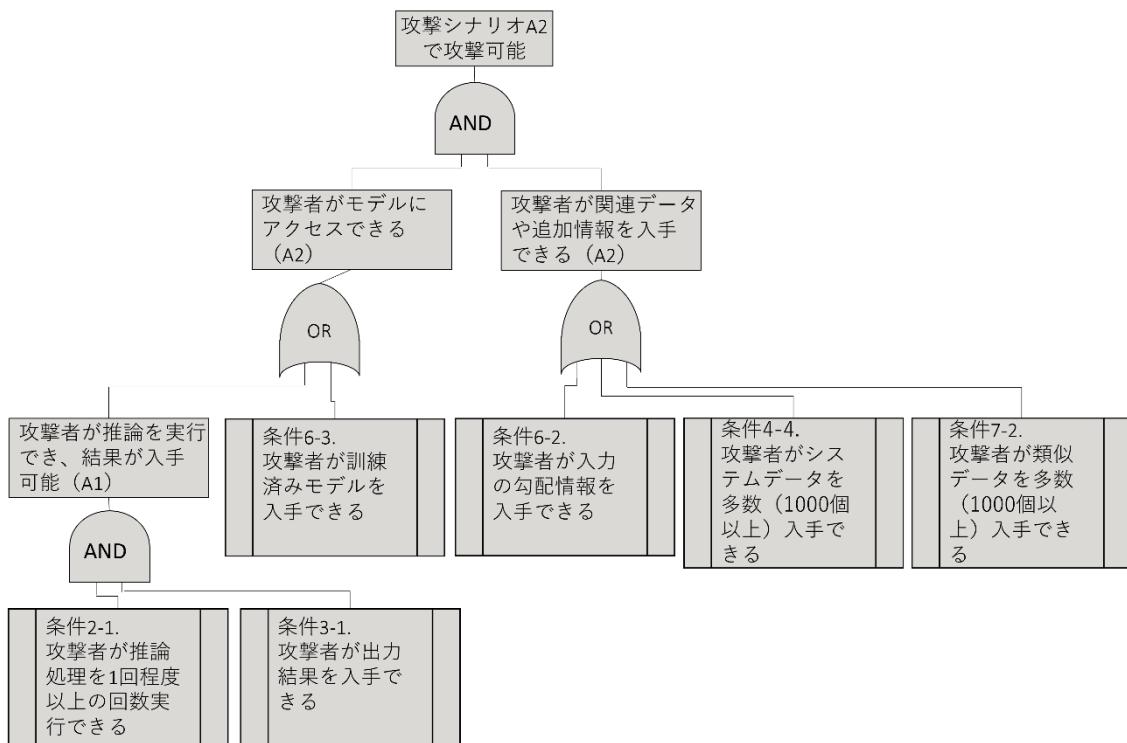


図 II- 16. 回避攻撃（敵対的サンプル）の攻撃シナリオ A2 のアタックツリーと攻撃実施可能条件

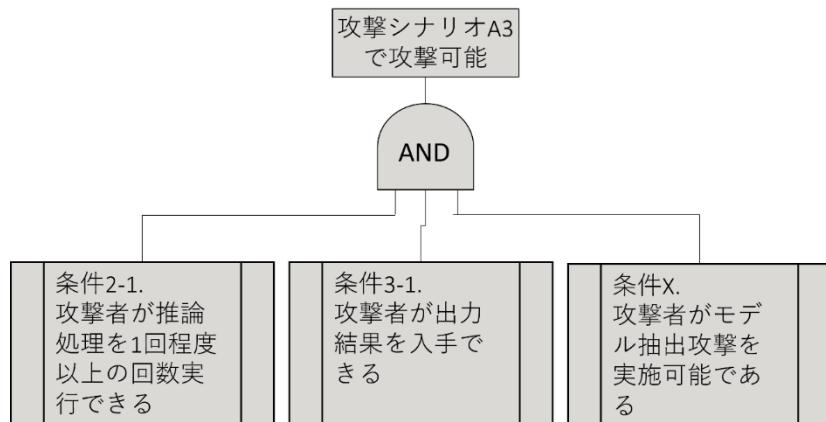


図 II- 17. 回避攻撃（敵対的サンプル）の攻撃シナリオ A3 のアタックツリーと攻撃実施可能条件

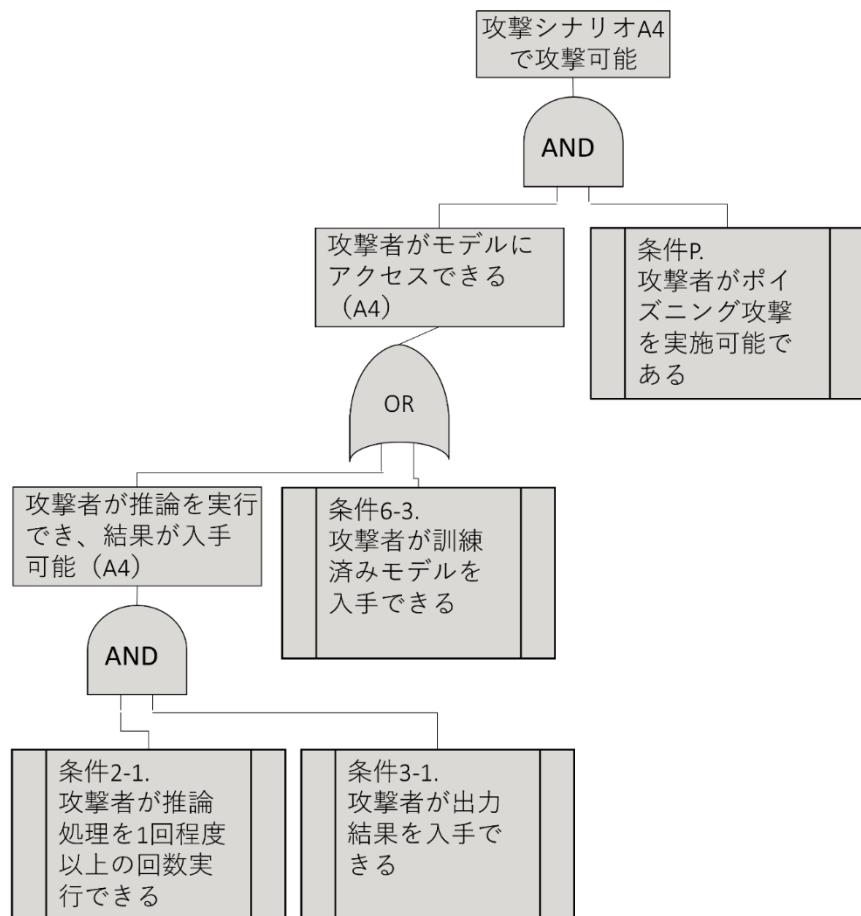


図 II- 18. 回避攻撃（敵対的サンプル）の攻撃シナリオ A4 のアタックツリーと攻撃実施可能条件

II-9.2.2. ポイズニング攻撃のアタックツリーと攻撃実施可能条件

ポイズニング攻撃についてのアタックツリーと攻撃実施可能条件は以下の通り抽出されている。

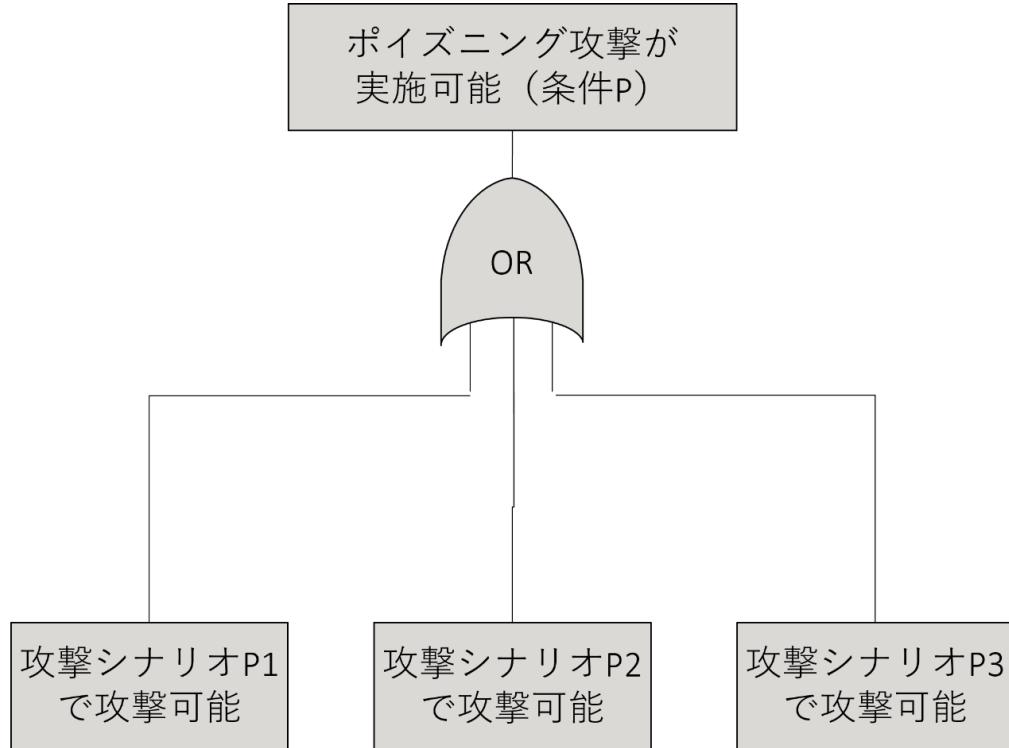


図 II- 19. ポイズニング攻撃のアタックツリー（上位部分）




図 II- 20. ポイズニング攻撃の攻撃シナリオ P1 のアタックツリーと攻撃実施可能条件

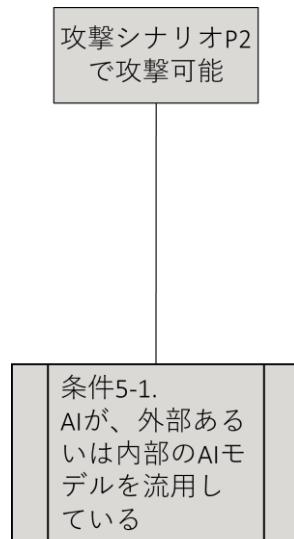


図 II- 21. ポイズニング攻撃の攻撃シナリオ P2 のアタックツリーと攻撃実施可能条件

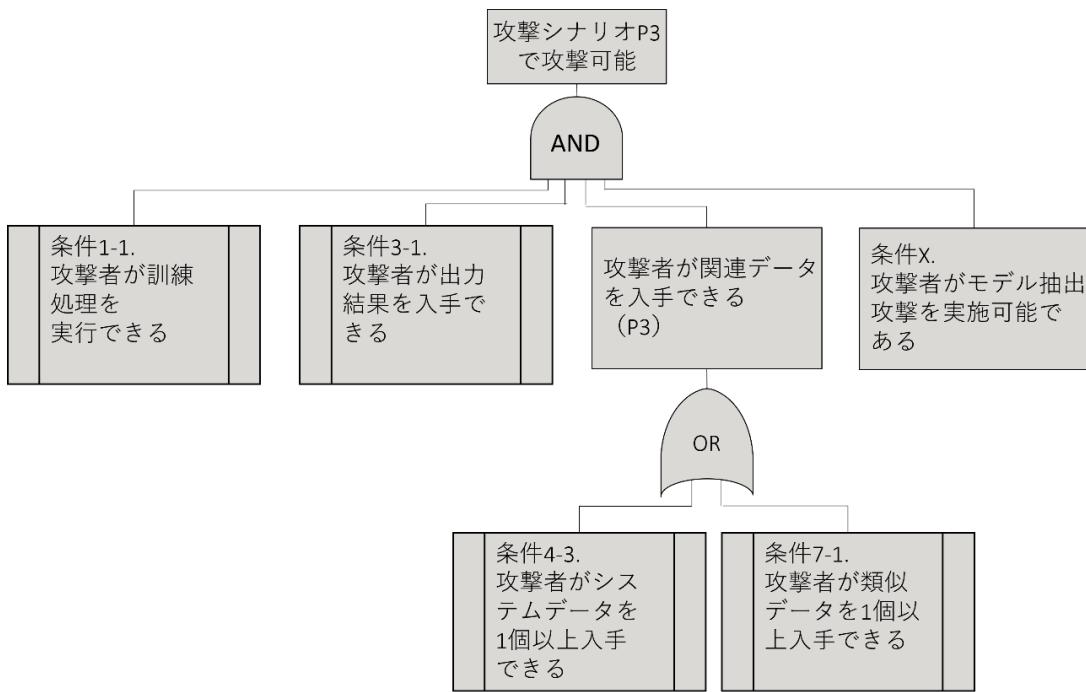


図 II- 22. ポイズニング攻撃の攻撃シナリオ P3 のアタックツリーと攻撃実施可能条件

II-9.2.3. モデル抽出攻撃のアタックツリーと攻撃実施可能条件

モデル抽出攻撃についてのアタックツリーと攻撃実施可能条件は以下の通り抽出されている。

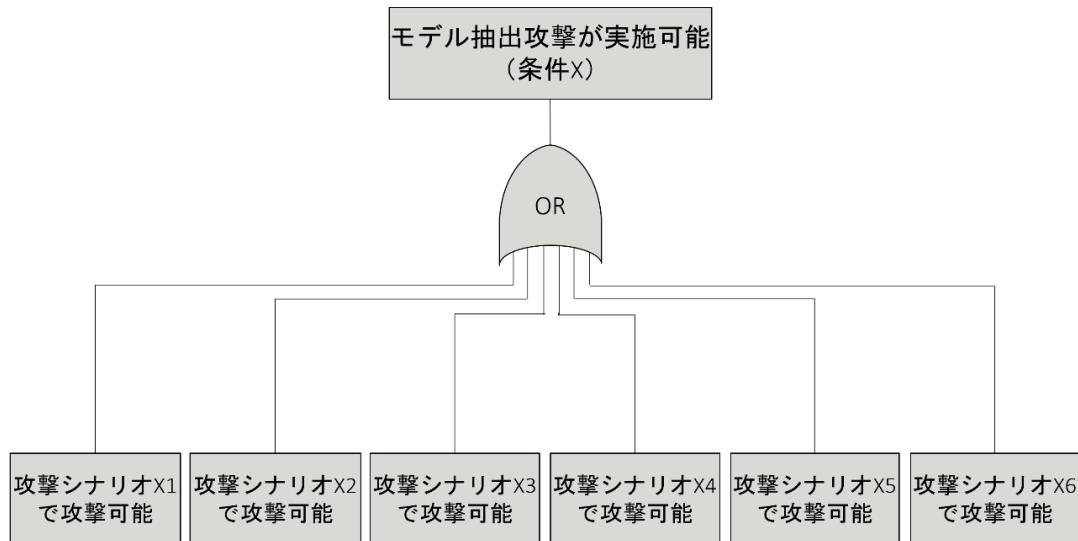


図 II- 23. モデル抽出攻撃のアタックツリー（上位部分）

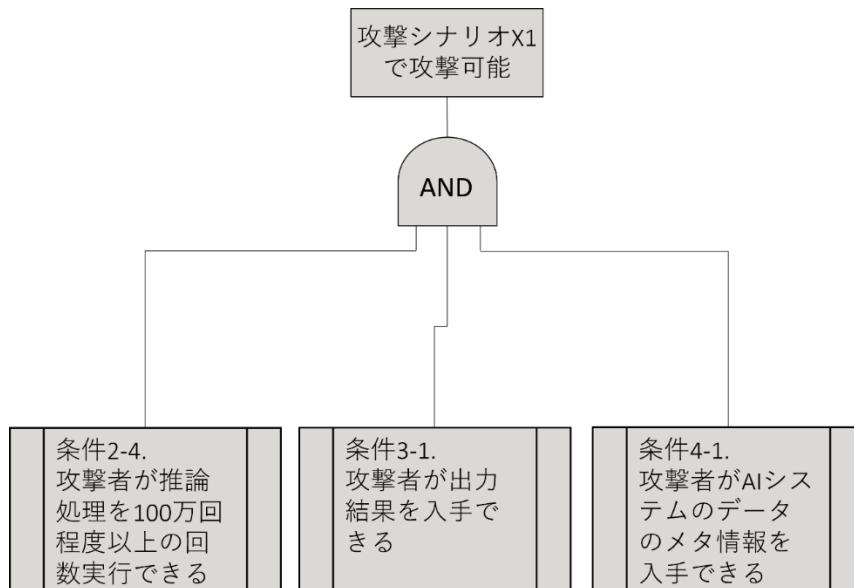


図 II- 24. モデル抽出攻撃の攻撃シナリオ X1 のアタックツリーと攻撃実施可能条件

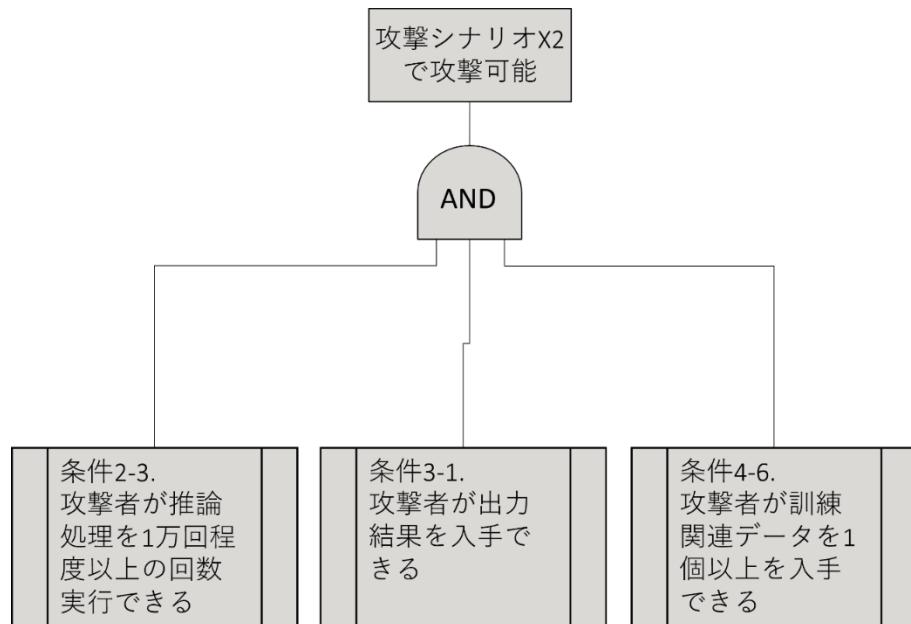


図 II- 25. モデル抽出攻撃の攻撃シナリオ X2 のアタックツリーと攻撃実施可能条件

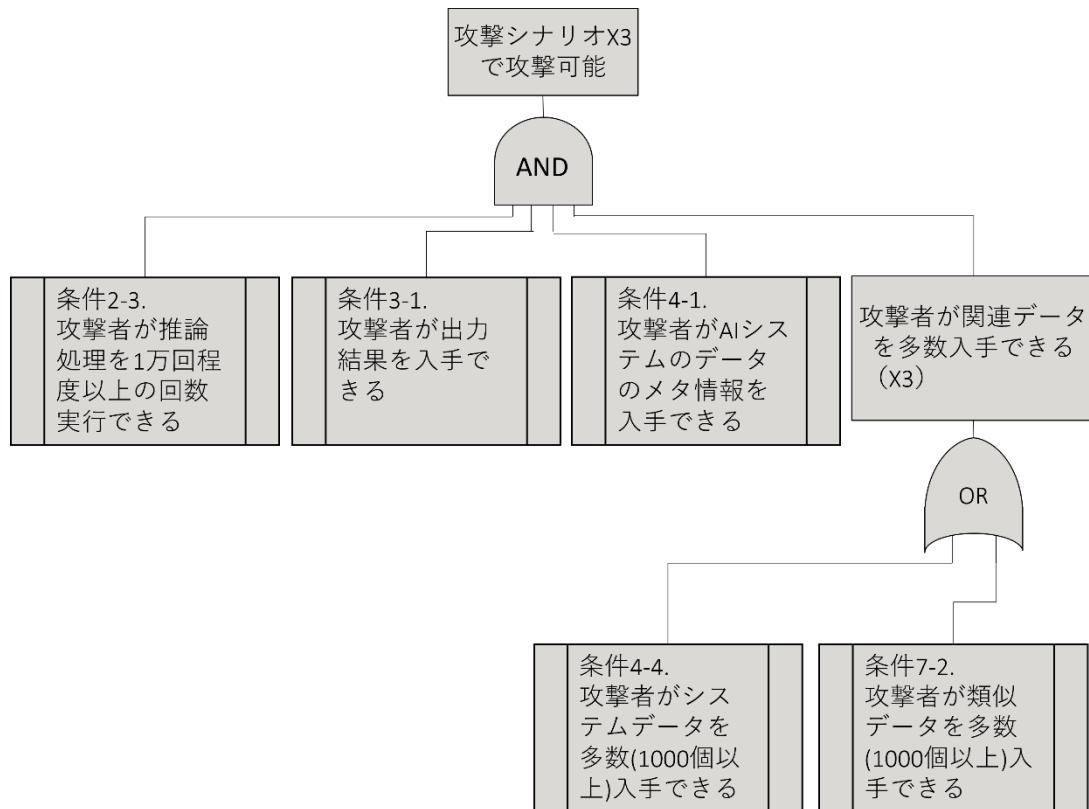


図 II- 26. モデル抽出攻撃の攻撃シナリオ X3 のアタックツリーと攻撃実施可能条件

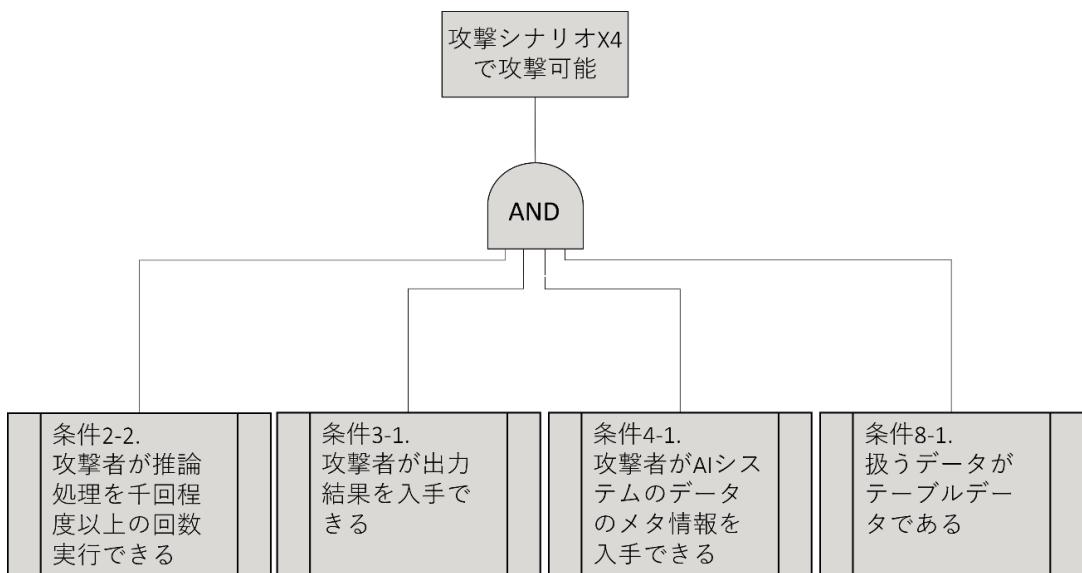


図 II- 27. モデル抽出攻撃の攻撃シナリオ X4 のアタックツリーと攻撃実施可能条件

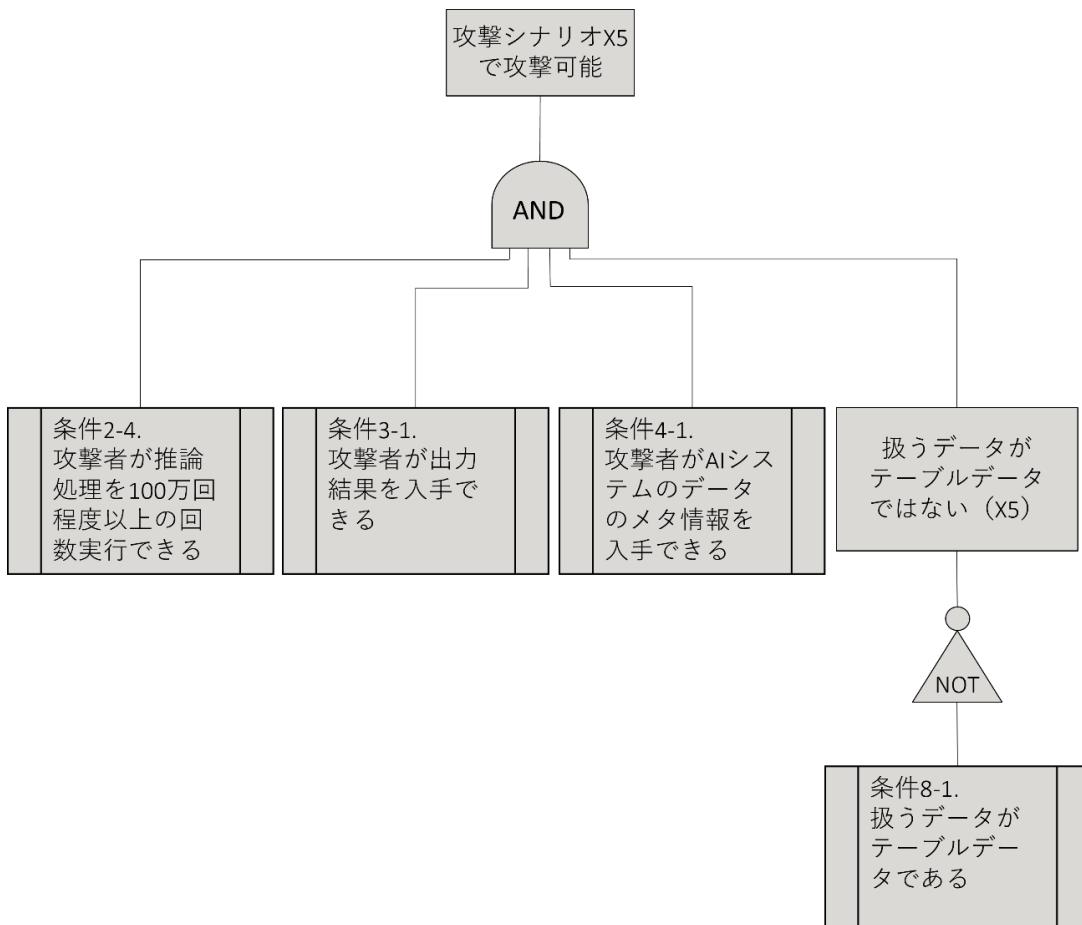


図 II- 28. モデル抽出攻撃の攻撃シナリオ X5 のアタックツリーと攻撃実施可能条件



図 II- 29. モデル抽出攻撃の攻撃シナリオ X6 のアタックツリーと攻撃実施可能条件

II-9.2.4. モデルインバージョン攻撃のアタックツリーと攻撃実施可能条件

モデルインバージョン攻撃についてのアタックツリーと攻撃実施可能条件は以下の通り抽出されている。

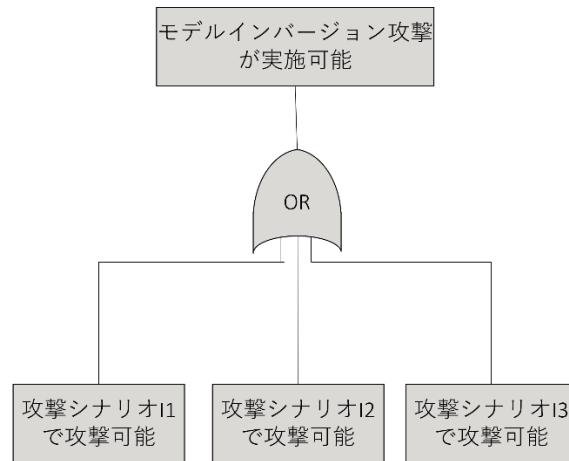


図 II-30. モデルインバージョン攻撃のアタックツリー（上位部分）

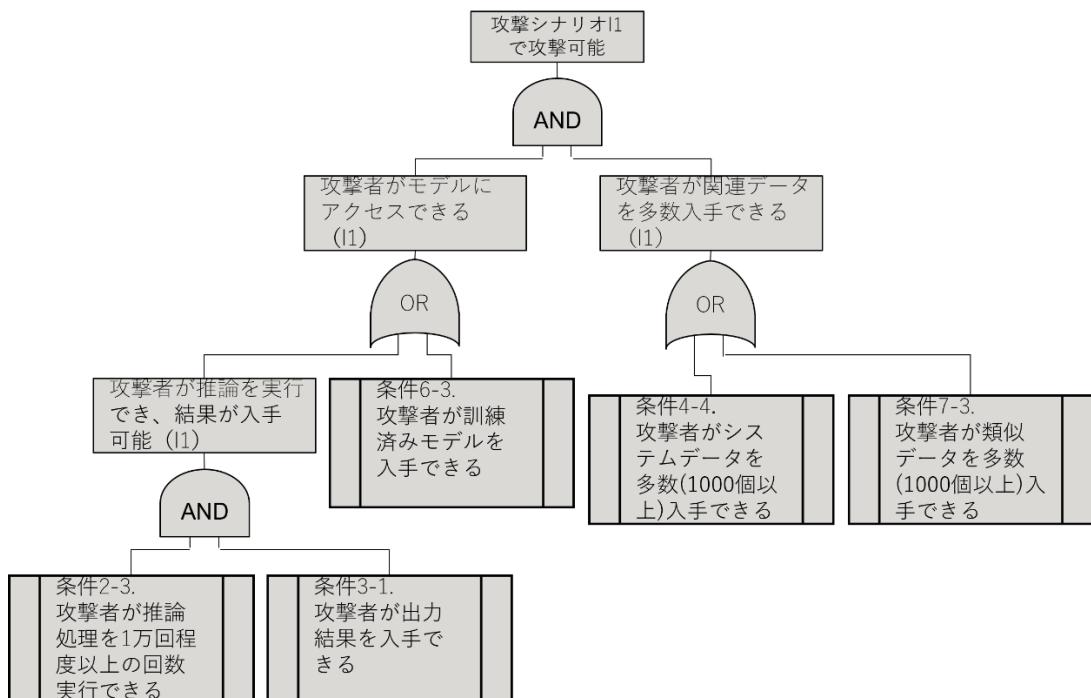


図 II-31. モデルインバージョン攻撃の攻撃シナリオ I1 のアタックツリーと
攻撃実施可能条件

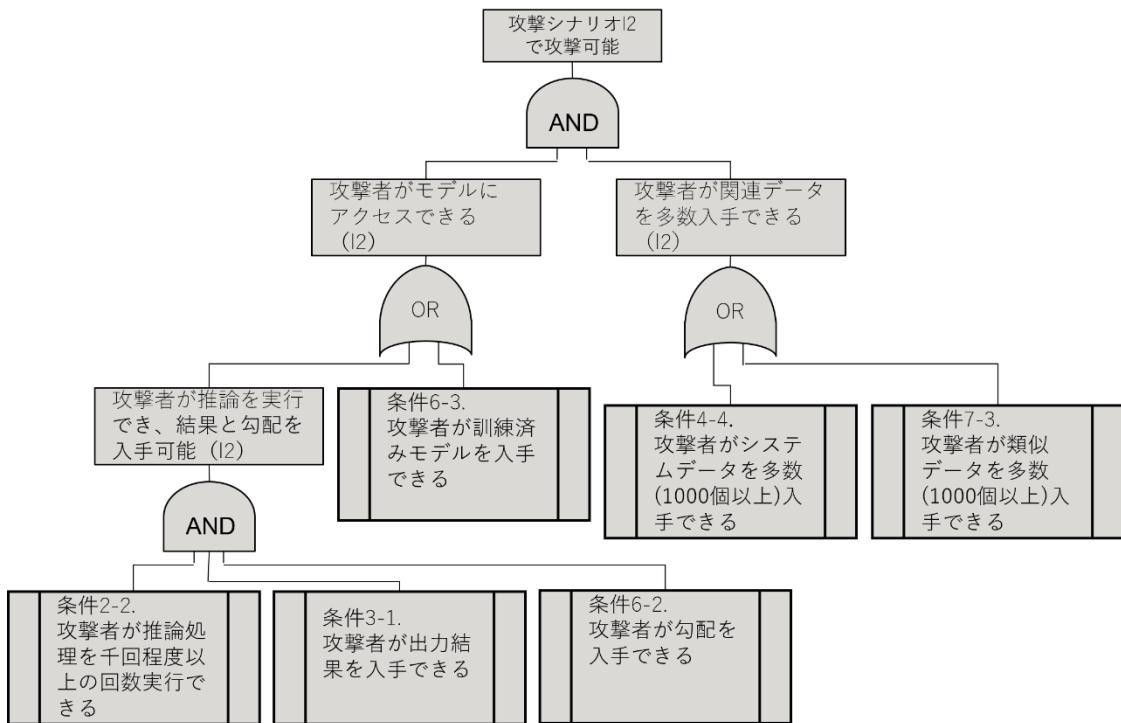


図 II- 32. モデルインバージョン攻撃の攻撃シナリオ I2 のアタックツリーと
攻撃実施可能条件

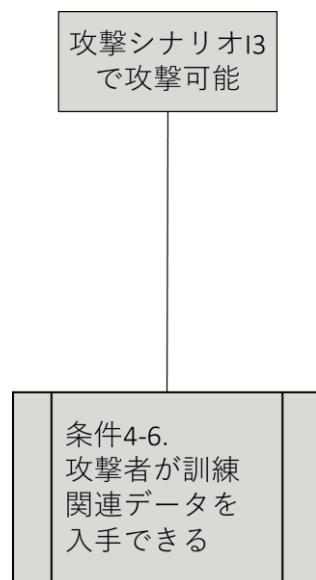


図 II- 33. モデルインバージョン攻撃の攻撃シナリオ I3 のアタックツリーと
攻撃実施可能条件

II-9.2.5. メンバシップ推測攻撃のアタックツリーと攻撃実施可能条件

メンバシップ推測攻撃についてのアタックツリーと攻撃実施可能条件は以下の通り抽出されている。





図 II-35. メンバシップ推測攻撃の攻撃シナリオ M1 のアタックツリーと攻撃実施可能条件

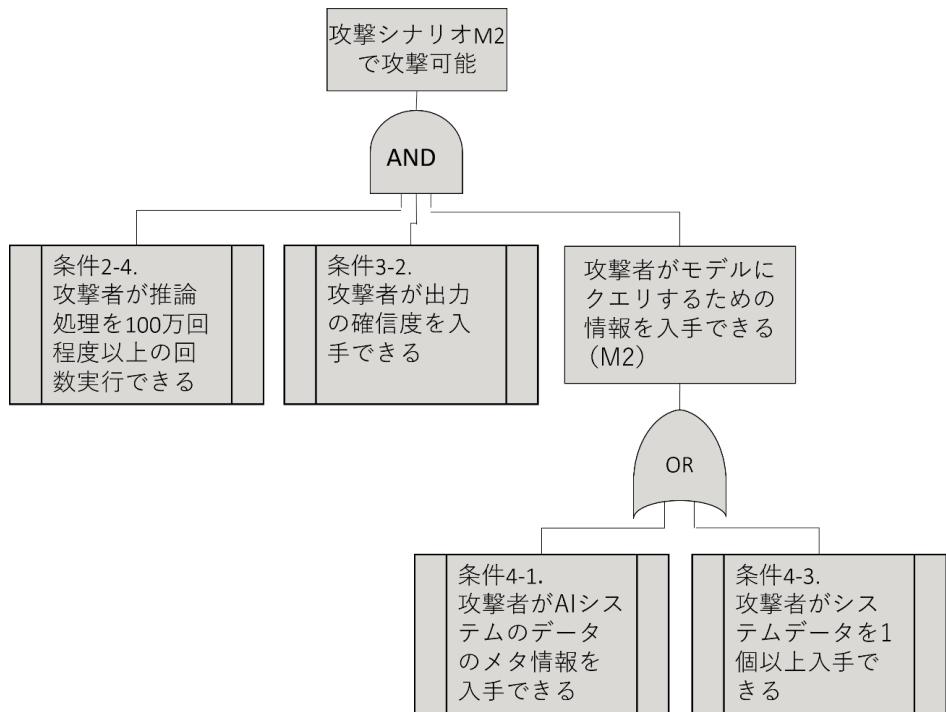


図 II- 36. メンバシップ推測攻撃の攻撃シナリオ M2 のアタックツリーと攻撃実施可能条件

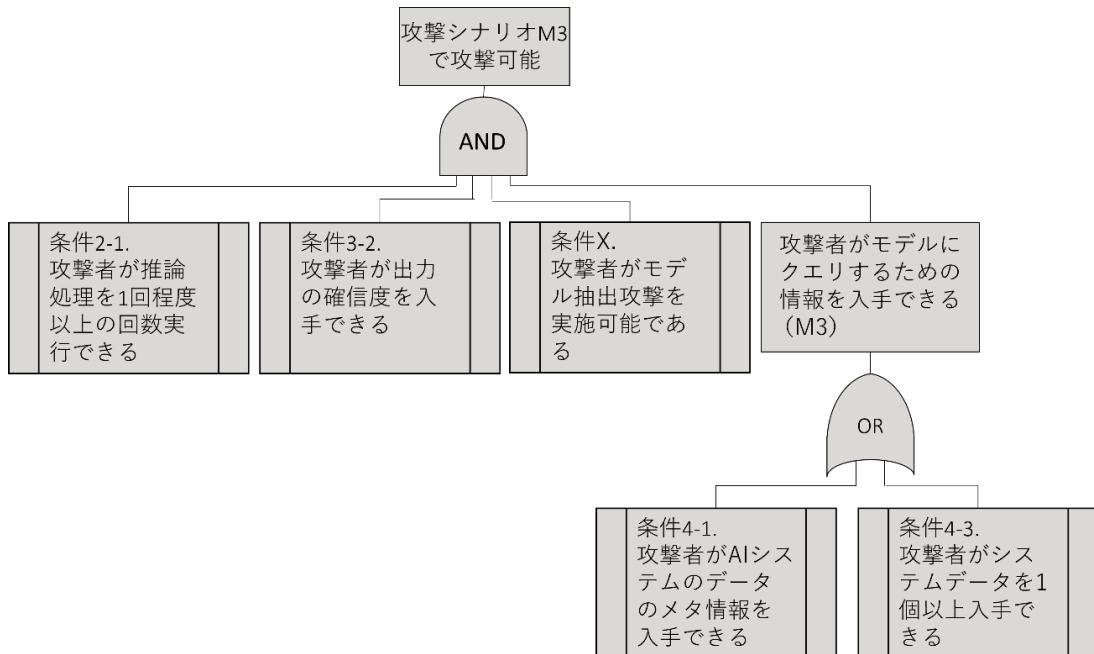


図 II- 37. メンバシップ推測攻撃の攻撃シナリオ M3 のアタックツリーと攻撃実施可能条件

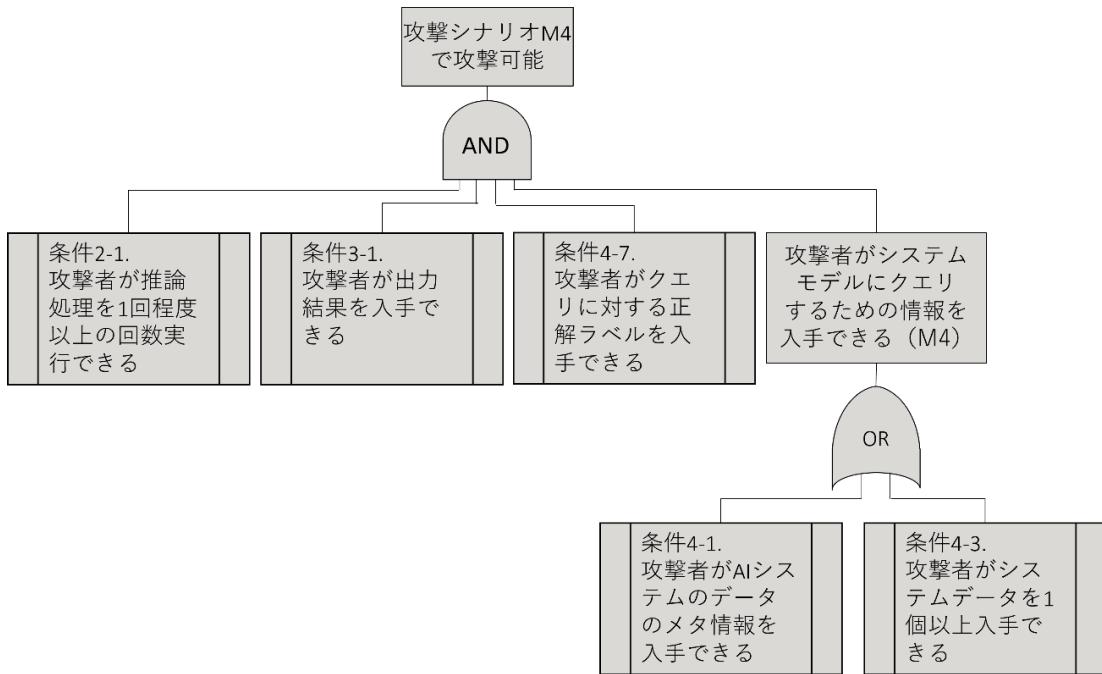


図 II- 38. メンバシップ推測攻撃の攻撃シナリオ M4 のアタックツリーと
攻撃実施可能条件

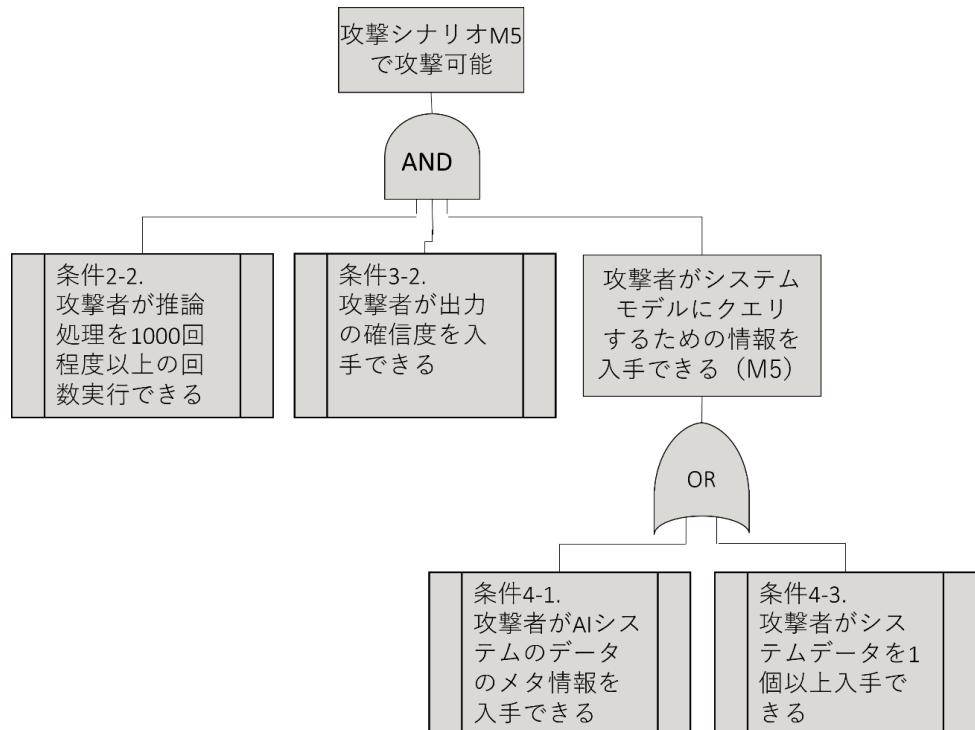


図 II- 39. メンバシップ推測攻撃の攻撃シナリオ M5 のアタックツリーと
攻撃実施可能条件

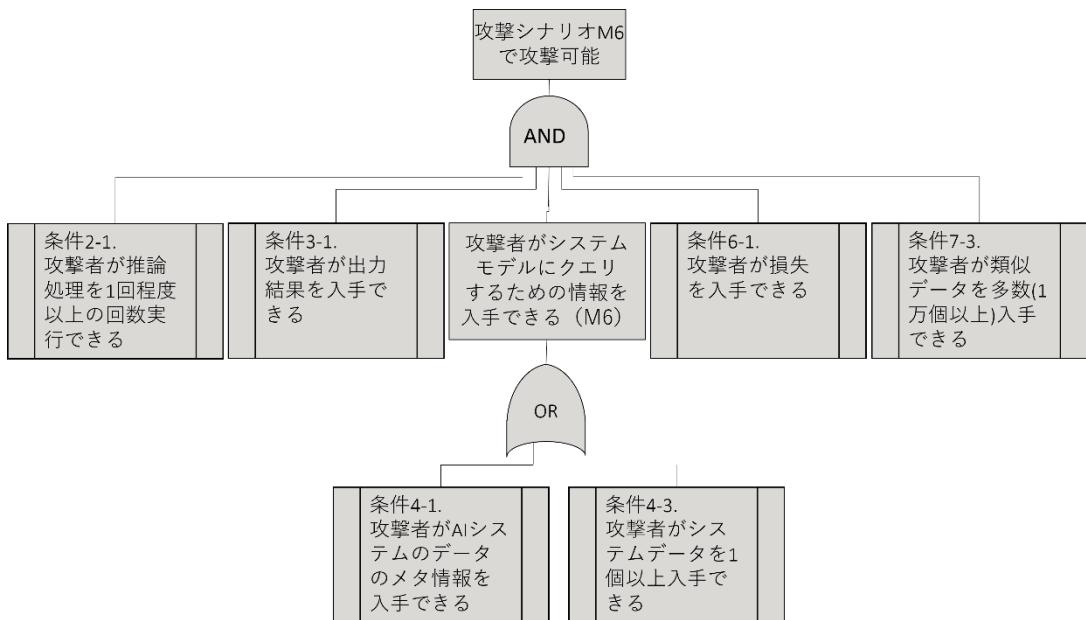


図 II- 40. メンバシップ推測攻撃の攻撃シナリオ M6 のアタックツリーと
攻撃実施可能条件

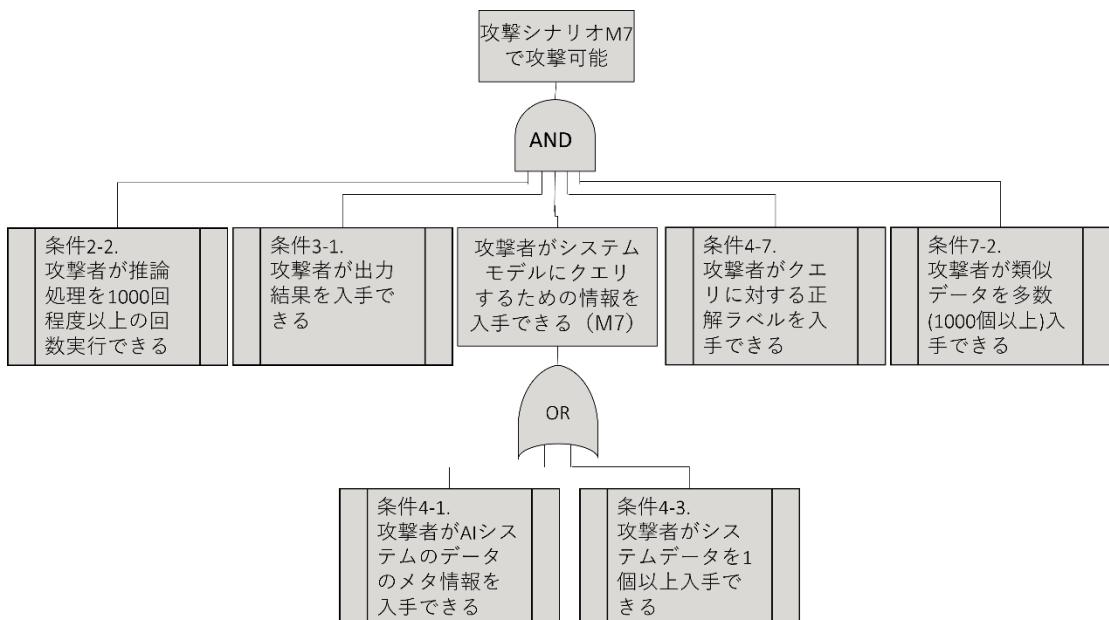


図 II- 41. メンバシップ推測攻撃の攻撃シナリオ M7 のアタックツリーと
攻撃実施可能条件

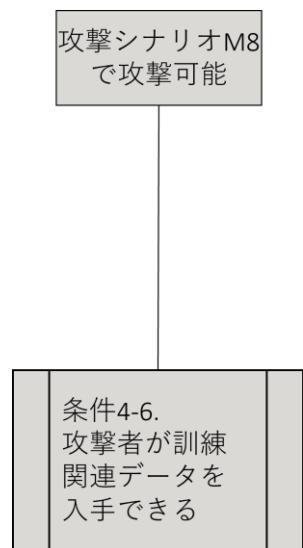


図 II- 42. メンバシップ推測攻撃の攻撃シナリオ M8 のアタックツリーと
攻撃実施可能条件

II-9.3. 質問群

II-9.2 節で掲載した攻撃実施可能条件に合致しているかどうかを聞き出すための質問は以下のとおりである。

1. 訓練処理の実行に関する質問

分析対象の AI システムが、想定攻撃者の意思で訓練処理を実行することができる場合は【1-1A】を、そうではない場合は【1-1B】をお答えください。

質問 1－1 A. 想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？

質問 1－1 B. 想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？

2. 推論処理可能なデータの個数に関する質問

分析対象の AI システムが、想定攻撃者の意思で推論処理を行える場合は【2-1A】を、自動で推論処理を行うシステムの場合は質問【2-1B】をお答えください。

質問 2－1 A. 想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？

①推論対象データ 1 個とは AI が処理する最小単位のデータの集まりです。テーブルデータなら 1 行、画像なら 1 枚です。

②想定攻撃者が推論処理を実行可能なデータの個数は、運用期間や推論処理の実行間隔などを考慮して導出してください。

③想定攻撃者が複数の利用者アカウントを作成できる場合、各利用者アカウントが実行した推論処理の合計数も考慮してください。

④物体検知 AI の場合、想定攻撃者が被写体を準備・細工でき、その被写体を撮影できる（推論処理できる）場合に当てはまります。

質問 2－2 A. 【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？

質問 2－3 A. 【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？

質問 2－4 A. 【2-3A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？

質問 2－1 B. 想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？

- ①推論対象データ 1 個とは AI が処理する最小単位のデータの集まりです。テーブルデータなら 1 行、画像なら 1 枚です。
- ②想定攻撃者が推論処理を実行可能なデータ個数は、運用期間や推論処理の実行間隔などを考慮して導出してください。
- ③物体検知 AI の場合、想定攻撃者が被写体を準備・細工でき、その被写体が撮影される（推論処理に入力される）場合に当てはまります。

質問 2－2B. 【2-1B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？

質問 2－3B. 【2-2B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？

質問 2－4B. 【2-3B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？

3. 出力結果の入手に関する質問

質問 3－1. 想定攻撃者にモデルの判定結果を提示しますか？

あるいは、想定攻撃者は判定結果を類推することができますか？

- ①判定結果とはモデルからの出力のことで、例えば分類タスクの場合には分類ラベル、回帰などの予測 AI においては予測結果などを指します
- ②物体検知 AI の場合、物体の検知結果と物体の位置情報を両方提示する場合に当てはまります

質問 3－2. モデルの確信度を一部でも想定攻撃者に提示しますか？

4. モデルが扱うデータの入手に関する質問

質問 4－1. 推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？

- ①メタ情報とは、テーブルデータを扱うデータの場合は AI システムの入力データのフォーマット（行・列の数、及び、要素の順序など）、画像を扱う AI システムにおいては縦横のピクセル数などを指します
- ②推論処理の実行 API がある場合、API を実行する際の入力データのメタ情報をなどを指します

質問 4－2. AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？

①統計情報とは、テーブルデータを扱うデータの場合の各列の数値データの平均や分散などを指します。

質問 4-3. AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、1 個以上入手できますか？

①入力データ 1 個とは AI が処理する最小単位のデータの集まりです。テーブルデータなら 1 行、画像なら 1 枚です。

②想定攻撃者が AI システムのタスクと入力データのメタ情報を知ることができます、推論対象データを生成・準備することができる場合は Yes です。

③推論処理の実行 API がある場合、実行 API への入力データが入手できるかを指します

質問 4-4. 【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ) を想定攻撃者が、1,000 個程度以上入手できますか？

①一人の想定攻撃者は 1 個しか入手できない場合でも複数の想定攻撃者が合計で 1,000 個以上入手できる場合は当てはまります

質問 4-5. 【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、10,000 個程度以上入手できますか？

質問 4-6. 訓練関連データに関して、想定攻撃者が 1 個以上入手できますか？

①訓練関連データ 1 個とは AI が処理する最小単位のデータの集まりです。テーブルデータなら 1 行、画像なら 1 枚です。

②訓練関連データは、訓練データ、バリデーションデータ、もしくはテストデータのことです

③物体検知 AI の場合、各データに物体の検知結果と物体の位置情報が含まれている場合に当てはまります。

質問 4-7. AI システムへ入力したデータに対する正解ラベルを想定攻撃者が入手できますか？

①正解ラベルとはモデルが推論したラベルではなく、真の正解ラベル (Ground Truth) です。

5. モデルの流用に関する質問

質問 5-1. 外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？

あるいは、AutoML を利用して AI を構築していますか？

- ①インターネットから入手したモデルを内部に流用している場合やインターネット以外でもあまり信頼できない入手先から入手したモデルを流用している場合に当てはまります
- ②信頼できる配布元から入手したモデル、あるいは信頼できる AutoML を利用している場合は当てはまりません

6. モデル情報の入手に関する質問

質問 6－1. 推論処理の際に入力された推論対象データに対する損失の情報を想定攻撃者が知ることができますか？

- ①想定攻撃者が判定結果しか得られない、あるいは判定結果すら得られないときは No です
- ②損失を入手できる関数を実行できるときなどは Yes です

質問 6－2. 推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撃者が知ることができますか？

- ①想定攻撃者が判定結果しか得られない、あるいは判定結果すら得られないときは No です
- ②勾配を入手できる関数を実行できるときは Yes です

質問 6－3. 訓練済みモデルそのものを想定攻撃者が何らかの方法で入手することができますか？

7. 類似データセットの入手に関する質問

質問 7－1. AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？

- ①類似データ 1 個とは AI が処理する最小単位のデータの集まりです。テキストデータなら 1 行、画像なら 1 枚です。
- ②物体検知 AI の場合、物体の検知結果と物体の位置情報が含まれる場合に当てはまります。

質問 7－2. 【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？

質問 7－3. 【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？

8. 扱うデータに関する質問

質問 8－1. システムで扱っているデータはテーブルデータですか？

- ①実行する AI のタスクとしてテーブルデータをターゲットとしている場合は Yes、そうでなければ No を選択してください
- ②前処理があった場合には前処理後のデータがテーブルになっていたら当てはまります

II-9.4. 攻撃実施可能条件の満足状況の判定用テーブル

II-9.2.5 節で示した質問群への回答を元に、II-9.2 節で抽出した攻撃実施可能条件に合致しているかを判定するテーブルは表 II- 5 のようになる。なお、対応案が採用しにくい場合には、ツリーを成立させないための別の条件を算出してそちらを FALSE にすることを試みるべきである。また、それでも対応しにくい場合には、機械学習セキュリティ専用の対策を導入すべきであり、専門家への相談を要する。

表 II- 5. 攻撃実施可能条件満足状況判定用テーブル

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1 – 1 A または質問 1 – 1 B が Yes		想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2 – 1 A または質問 2 – 1 B が Yes		想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2 – 2 A または質問 2 – 2 B が Yes		想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2 – 3 A または質問 2 – 3 B が Yes		想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2 – 4 A または質問 2 – 4 B が Yes		想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3 – 1 、または質問 3 – 2 が Yes		判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3 – 2 が Yes		判定結果の確信度を想定攻撃者に提示しないようにする

条件 4-1	データのメタ情報を入手可能	質問 4－1 が Yes		訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報が入手可能	質問 4－2 が Yes		訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする
条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes		訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4－4 が Yes		訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes		訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。

条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes		訓練関連データを想定攻撃者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes		システムの詳細な仕様を公開せず、想定攻撃者に真の正解ラベル (Ground Truth) を推測されないようにする
条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes		信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes		損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes		勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes		訓練済みモデルを管理し、外部に流出しないようにする
条件 7-1	類似データを 1 個以上入手可能	質問 7－1 が Yes		システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを千個以上入手可能	質問 7－2 が Yes		システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを 1 万個以上入手可能	質問 7－3 が Yes		システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする

条件 8-1	扱うデータが テーブルデータ	質問 8 – 1 が Yes		テーブルデータを扱う AI システムなのか画像 データを扱う AI システム なのか、利用形態が適切 であるかを確認する
--------	-------------------	-------------------	--	--

II-9.5. AI リスク問診ツール

本章で説明した AI リスク問診の実現例をツールとして実装したものを本ガイドラインと同時に公開する。本ツールは Microsoft Excel で構成されている。I. AI の定義 と、II. 質問 のタブに書かれているシートを埋めると IV. 総合判定結果以降に判定結果が表示される。詳細はツールに付属の `readme`、及び、ツール内の説明を参照して頂きたい。

II-10. セキュリティリスク分析の試行例

この章では II-7 章と、II-9 章で紹介した影響分析と脅威分析の実現例を利用した、機械学習システムの分析事例を紹介する。

II-10.1. 事例試行概要

[II-9]では、標識識別 AI に対する試行例が掲載されている。これに対して今回、策定委員において 3 つの事例について試行を実施した。事例を以下に示す。本章ではこれらの試行結果を紹介する。

- ・融資審査 AI
- ・プラント制御 AI
- ・性別・年齢推定 AI

II-10.1.1. 融資審査 AI

仕様：融資申込者が返済できるかどうかを予測する AI

金融情報と融資申込者の情報をデータ処理担当者が訓練してモデルを構築する。融資申込者の情報を金融担当者が入力し、AI が返済できるかどうかを予測（分類）する。推論結果は金融担当者のみが知ることができる。融資申込者には結果を見せない。

- ・影響分析

1. ヒアリングシート

項目	記入内容
目的	融資申込者の情報から融資可能かどうかを判断する
訓練者	自社で訓練
訓練済モデルの秘密度	重要機密
訓練データの内容	申込者情報と金融機関情報
訓練データの入手先	自社が所有する過去の融資情報
訓練データの公開度	非公開
AI に関連する人々	金融機関担当者、開発者、融資申込者
AI に関連する物品	分析 PC

2. 影響分析の準備シート

項目	記入内容
目的の反転	融資可能である申込者に融資しない。融資可能でない申込者に

	融資する
AI の誤判断の想定被害者	金融機関、融資申込者
AI の誤判断の想定被害物品	なし
訓練済モデル漏洩の想定被害者	金融機関
訓練データ漏洩の想定被害者	金融機関

3. AI の誤判断被害の分析シート

○AI の誤判断被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	融資審査支援 AI
どうして	AI の誤判断を起こさせて
誰に（何に）	融資申込者
どうなる	融資が受けられるのに融資が受けられない
「どうなる」により生じる具体的な影響	必要な物品（不動産など）が購入できなくなる
引き起こされる被害	資金不足（金銭被害）
対処必要性	中

被害例 2

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	融資審査支援 AI
どうして	AI の誤判断を起こさせて
誰に（何に）	金融機関
どうなる	融資してはいけない申込者に融資してしまう
「どうなる」により生じる具体的な影響	資金が回収できなくなり、金銭的損害を受

	ける
引き起こされる被害	資金が回収できない（金銭被害）
対処必要性	大

4. 情報漏洩被害の分析シート

○訓練済モデルの漏洩被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	融資審査支援 AI
どうして	訓練済モデルを漏洩（奪取）して
誰に	金融機関
どうなる	訓練済モデルを盗まれる
引き起こされる被害	他社にノウハウが盗まれる（その他の被害）
対処必要性	大

○訓練データの漏洩被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	融資審査支援 AI
どうして	訓練データを漏洩（奪取）して
誰に	金融機関
どうなる	訓練データを盗まれる
引き起こされる被害	顧客の信頼を失う（その他の被害）
対処必要性	大

・脅威分析

1. 想定攻撃者＝データ処理担当者

(i) 質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	Yes
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	-
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	Yes
2-4A	【2-3A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	Yes
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-4B	【2-3B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	Yes
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	Yes
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	Yes

4-2	AI システムに用いられた訓練データの統計情報を想定攻撲者は知ることができますか？	Yes
4-3	AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ)を想定攻撲者が、1 個以上入手できますか？	Yes
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ)を想定攻撲者が、1,000 個程度以上入手できますか？	Yes
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ)を想定攻撲者が、10,000 個程度以上入手できますか？	Yes
4-6	訓練関連データに関して、想定攻撲者が 1 個以上入手できますか？	Yes
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撲者が入手できますか？	Yes
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	No
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撲者が知ることができますか？	Yes
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撲者が知ることができますか？	Yes
6-3	訓練済みモデルそのものを想定攻撲者が何らかの方法で入手することができますか？	Yes
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撲者が 1 個以上、何らかの手段で準備・入手できますか？	Yes
7-3	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撲者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
7-4	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撲者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
8-1	システムで扱っているデータはテーブルデータですか？	Yes

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1-1 A または質問 1-1 B が Yes	TRUE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2-1 A または質問 2-1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2-2 A または質問 2-2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2-3 A または質問 2-3 B が Yes	TRUE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2-4 A または質問 2-4 B が Yes	TRUE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3-1、または質問 3-2 が Yes	TRUE	判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3-2 が Yes	TRUE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4-1 が Yes	TRUE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報を入手可能	質問 4-2 が Yes	TRUE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする

条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4－4 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes	TRUE	訓練関連データを想定攻撲者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes	TRUE	システムの詳細な仕様を公開せず、想定攻撲者に真の正解ラベル (Ground Truth) を推測されないようにする

条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes	FALSE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	TRUE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	TRUE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	TRUE	訓練済みモデルを管理し、外部に流出しないようする
条件 7-1	類似データを1個以上入手可能	質問 7－1 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを千個以上入手可能	質問 7－2 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを1万個以上入手可能	質問 7－3 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 8-1	扱うデータがテーブルデータ	質問 8－1 が Yes	TRUE	テーブルデータを扱うAIシステムなのか画像データを扱うAIシステムなのか、利用形態が適切であるかを確認する

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：A1, A2, A3, A4

ポイズニング攻撃：P1, P3

モデル抽出攻撃 : X1, X2, X3, X4, X6

モデルインバージョン攻撃 : I1, I2, I3

メンバシップ推測攻撃 : M1, M2, M3, M4, M5, M6, M7, M8

(iv) 分析結果

P2, X5 以外のすべてのシナリオで攻撃実施可能と判定された。データ処理担当者は AI 開発者と同等であり、権限が大きいためこのような結果となったと考えられる。

2. 想定攻撃者=金融担当者

(i) 質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	Yes
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	-
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	No
2-4A	【2-3A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	No
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-

	て、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	
2-4B	【2-3B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	Yes
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	Yes
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	Yes
4-2	AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？	Yes
4-3	AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、1 個以上入手できますか？	Yes
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ) を想定攻撃者が、1,000 個程度以上入手できますか？	Yes
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、10,000 個程度以上入手できますか？	Yes
4-6	訓練関連データに関して、想定攻撃者が 1 個以上入手できますか？	Yes
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撃者が入手できますか？	Yes
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	No
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撃者が知ることができますか？	No
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撃者が知ることができますか？	No
6-3	訓練済みモデルそのものを想定攻撃者が何らかの方法で入手	Yes

	することができますか？	
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？	Yes
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
8-1	システムで扱っているデータはテーブルデータですか？	Yes

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1-1 A または質問 1-1 B が Yes	TRUE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2-1 A または質問 2-1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2-2 A または質問 2-2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2-3 A または質問 2-3 B が Yes	FALSE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2-4 A または質問 2-4 B が Yes	FALSE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果を入手可能	質問 3-1、または質問 3-2 が Yes	TRUE	判定結果を想定攻撃者に提示しないようにする

条件 3-2	確信度を入手可能	質問 3－2 が Yes	TRUE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4－1 が Yes	TRUE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報が入手可能	質問 4－2 が Yes	TRUE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする
条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4－4 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入

				手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4 – 6 が Yes	TRUE	訓練関連データを想定攻撃者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4 – 7 が Yes	TRUE	システムの詳細な仕様を公開せず、想定攻撃者に真の正解ラベル (Ground Truth) を推測されないようにする
条件 5-1	転移性を利用したモデルの開発	質問 5 – 1 が Yes	FALSE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6 – 1 が Yes	FALSE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6 – 2 が Yes	FALSE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自身を入手可能	質問 6 – 3 が Yes	TRUE	訓練済みモデルを管理し、外部に流出しないようにする
条件 7-1	類似データを 1 個以上入手可能	質問 7 – 1 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを 千個以上入手可能	質問 7 – 2 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを 1 万個以上入手可能	質問 7 – 3 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする

条件 8-1	扱うデータが テーブルデータ	質問 8 – 1 が Yes	TRUE	テーブルデータを扱う AI システムなのか画像 データを扱う AI システム なのか、利用形態が適切 であるかを確認する
--------	-------------------	-------------------	------	--

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：A1, A2, A3, A4

ポイズニング攻撃：P1, P3

モデル抽出攻撃：X4, X6

モデルインバージョン攻撃：I1, I2, I3

メンバシップ推測攻撃：M3, M4, M5, M7, M8

(iv) 分析結果

金融担当者は自身の結果を金融情報に反映できるため質問 1 も Yes となった。ただし、データ処理担当者と異なり、業務外で大量の推論処理は実行できないため、このような結果となった。

3. 想定攻撃者＝第三者（融資申込者等）

(i) 質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	-
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	No
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	No
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行す	No

	ることができますか？	
2-4A	【2-3A】が Yes であった場合、想定攻撃者は 【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	No
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-4B	【2-3B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	No
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	No
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	No
4-2	AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？	No
4-3	AI システムへの入力データそのもの（訓練データ or バリデーションデータ or テストデータ or 推論対象データ）を想定攻撃者が、1 個以上入手できますか？	No
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの（訓練データ or テストデータ or 推論対象データ）を想定攻撃者が、1,000 個程度以上入手できますか？	No
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの（訓練データ or バリデーションデータ or テストデータ or 推論対象データ）を想定攻撃者が、10,000 個程度以上入手できますか？	No
4-6	訓練関連データに関して、想定攻撃者が 1 個以上入手できますか？	No

4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撲者が入手できますか？	No
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？あるいは、AutoML を利用して AI を構築していますか？	No
6-1	推論処理の際に入力された推論対象データに対する損失の情報を見たがる事ができますか？	No
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を見たがる事ができますか？	No
6-3	訓練済みモデルそのものを想定攻撃者が何らかの方法で入手することができますか？	No
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？	No
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	No
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	No
8-1	システムで扱っているデータはテーブルデータですか？	Yes

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1 - 1 A または質問 1 - 1 B が Yes	FALSE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2 - 1 A または質問 2 - 1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2 - 2 A または質問 2 - 2 B が Yes	FALSE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する

条件 2-3	推論処理を 1 万個以上で実行可能	質問 2 – 3 A または質問 2 – 3 B が Yes	FALSE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2 – 4 A または質問 2 – 4 B が Yes	FALSE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3 – 1、または質問 3 – 2 が Yes	FALSE	判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3 – 2 が Yes	FALSE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4 – 1 が Yes	FALSE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報が入手可能	質問 4 – 2 が Yes	FALSE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする
条件 4-3	システムデータを 1 個以上入手可能	質問 4 – 3 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4 – 4 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ

				情報を想定攻撃者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes	FALSE	訓練関連データを想定攻撃者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes	FALSE	システムの詳細な仕様を公開せず、想定攻撃者に真の正解ラベル (Ground Truth) を推測されないようにする
条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes	FALSE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	FALSE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	FALSE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	FALSE	訓練済みモデルを管理し、外部に流出しないようにする

条件 7-1	類似データを 1 個以上入手 可能	質問 7－1 が Yes	FALSE	システムの利用目的や訓 練関連データの詳細な仕 様を想定攻撃者が入手、 推定できないようにする
条件 7-2	類似データを 千個以上入手 可能	質問 7－2 が Yes	FALSE	システムの利用目的や訓 練関連データの詳細な仕 様を想定攻撃者が入手、 推定できないようにする
条件 7-3	類似データを 1 万個以上入 手可能	質問 7－3 が Yes	FALSE	システムの利用目的や訓 練関連データの詳細な仕 様を想定攻撃者が入手、 推定できないようにする
条件 8-1	扱うデータが テーブルデー タ	質問 8－1 が Yes	TRUE	テーブルデータを扱う AI システムなのか画像 データを扱う AI シス テムなのか、利用形態が適 切であるかを確認する

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：なし

ポイズニング攻撃：なし

モデル抽出攻撃：なし

モデルインバージョン攻撃：なし

メンバシップ推測攻撃：なし

(iv) 分析結果

融資申込者を含む第三者は、自身が申し込むことで AI を間接的に実行させることはでき、自身のデータを入力することができる。しかし結果を入手することはできない。このため、想定した全ての攻撃シナリオについて実施困難と判定された。

・セキュリティリスク分析結果の考察

影響分析により、全ての被害について、対処必要性が大や中となったため、対応が必要と考えられる。全ての攻撃への対応が必要である。

脅威分析により、想定攻撃者がデータ処理担当者と金融担当者のケースで全攻撃が実施可能と判定された。これらの想定攻撃者は内部犯であり、内部犯が存在すると全ての攻撃が実施できると判断される。想定攻撃者が第三者のケースでは、全ての攻撃シナ

リオが「実施困難」となった。

これらから、融資の申込者を含めた外部の人々からの攻撃は実施困難であると考えられ、影響分析で明らかになった誤判断被害、訓練済モデル漏洩被害、訓練データ漏洩被害は直ちには実施することは難しいと判断できる。内部犯を許容しないケースにおいては全ての攻撃に対策が必要となる。

II-10.1.2. プラント制御 AI

仕様：プラントの酸素供給量の判断を行う AI

センサから得た情報を元に酸素供給量を判断する。訓練はプラント関係者が行う。推論は定期的に行われ、人間は関与しない。今回は第三者により攻撃が実施可能かどうかを分析した。第三者はセンサを自身で作成したものに置き換えて AI システムにデータを送る想定とした。また、プラントは 1 日 1 回見回りに来ることを想定し、最大でも 24 時間しか異常なデータは流せないこととした。

・影響分析

1. ヒアリングシート

項目	記入内容
目的	センサから得られた情報を元に適切な酸素供給量を推定する
訓練者	(納品先企業のデータを使って) 自社で訓練
訓練済モデルの秘密度	重要機密
訓練データの内容	センサ値の情報と適切な酸素供給量の情報
訓練データの入手先	納品先企業が保有する過去のセンサ値と酸素供給量が格納された PC
訓練データの公開度	非公開
AI に関連する人々	(顧客側) プラント管理作業者(オペレータ)、プラント運営会社、(自社側) AI システム開発者(含モデル開発者)
AI に関連する物品	センサ[炉内温度センサ、炉内酸素センサ、外気温、外湿度、風速、(.etc)]、酸素供給装置(ファン)、ゴミ処理炉

2. 影響分析の準備シート

項目	記入内容
目的の反転	センサから得られた情報を元に、適切な酸素供給量を推定できない
AI の誤判断の想定被害	プラント管理作業者、プラント運営会社

者	
AI の誤判断の想定被害物品	酸素供給装置、ゴミ焼却炉
訓練済モデル漏洩の想定被害者	プラント運営会社
訓練データ漏洩の想定被害者	プラント運営会社

3. AI の誤判断被害の分析シート

○AI の誤判断被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	ゴミ処理場のプラント自動制御 AI に
どうして	AI の誤判断を起こさせて
誰に（何に）	プラント管理作業者が
どうなる	適切な手動制御が行えない
「どうなる」により生じる具体的な影響	酸素過多になり燃焼しすぎる。または、不完全燃焼で一酸化炭素が生成される
引き起こされる被害	一酸化炭素中毒となる（人的被害） プラント毀損、不祥事がニュースになる（その他の被害）
対処必要性	大

被害例 2

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	ゴミ処理場のプラント自動制御 AI に
どうして	AI の誤判断を起こさせて
誰に（何に）	プラント運営会社が
どうなる	余計な費用がかかる
「どうなる」により生じる具体的な影響	制御がうまくできない場合、追加の燃料が必要となる。また、プラントに損傷が生じ

	れば、復旧費用も必要となる
引き起こされる被害	余計な燃料が必要となる。プラントの復旧費用がかかる（金銭的被害）
対処必要性	中

被害例 3

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	ゴミ処理場のプラント自動制御 AI に
どうして	AI の誤判断を起こさせて
誰に（何に）	酸素供給装置が
どうなる	停止する
「どうなる」により生じる具体的な影響	酸素供給が不要だと判断して停止し、その結果燃焼が止まってしまう
引き起こされる被害	再始動に費用がかかる（金銭的被害）
対処必要性	中

被害例 4

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	ゴミ処理場のプラント自動制御 AI に
どうして	AI の誤判断を起こさせて
誰に（何に）	ゴミ焼却炉が
どうなる	異常な高温になる
「どうなる」により生じる具体的な影響	過剰な燃焼が行われ、ゴミ焼却炉が高温状態に達し、破損する
引き起こされる被害	ゴミ焼却炉の復旧費用がかかる（金銭的被害）
対処必要性	中

4. 情報漏洩被害の分析シート

○訓練済モデルの漏洩被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	ゴミ焼却炉のプラント自動制御 AI から
どうして	訓練済モデルを漏洩（奪取）して
誰に	プラント運営会社から
どうなる	訓練済モデルを盗まれる
引き起こされる被害	攻撃のための解析に使われる（その他の被害）
対処必要性	小

○訓練データの漏洩被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	ゴミ焼却炉のプラント自動制御 AI から
どうして	訓練データを漏洩（奪取）して
誰に	プラント運営会社から
どうなる	訓練データを盗まれる
引き起こされる被害	起業ノウハウの流出、ブランド毀損（精神的被害） 攻撃のための解析に使われる（その他の被害）
対処必要性	小

・脅威分析

1. 想定攻撃者=第三者

(i)質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が	-

	訓練処理を実行することができますか？	
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	No
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	-
2-2A	【2-1A】が Yes であった場合、想定攻撃者は 【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	-
2-3A	【2-2A】が Yes であった場合、想定攻撃者は 【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	-
2-4A	【2-3A】が Yes であった場合、想定攻撃者は 【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	-
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	Yes
2-2B	【2-1B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	Yes
2-3B	【2-2B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	Yes
2-4B	【2-3B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	No
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	No
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	No
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	No
4-2	AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？	No
4-3	AI システムへの入力データそのもの(訓練データ or バリデ	Yes

	ーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、1 個以上入手できますか？	
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのものの(訓練データ or テストデータ or 推論対象データ) を想定攻撃者が、1,000 個程度以上入手できますか？	Yes
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのものの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、10,000 個程度以上入手できますか？	Yes
4-6	訓練関連データに関して、想定攻撃者が 1 個以上入手できますか？	No
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撃者が入手できますか？	No
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	No
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撃者が知ることができますか？	No
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撃者が知ることができますか？	No
6-3	訓練済みモデルそのものを想定攻撃者が何らかの方法で入手することができますか？	No
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？	No
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	No
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	No
8-1	システムで扱っているデータはテーブルデータですか？	Yes

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案

条件 1-1	訓練処理の自由な実行が可能	質問 1－1 A または質問 1－1 B が Yes	FALSE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2－1 A または質問 2－1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2－2 A または質問 2－2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2－3 A または質問 2－3 B が Yes	TRUE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2－4 A または質問 2－4 B が Yes	FALSE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3－1、または質問 3－2 が Yes	FALSE	判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3－2 が Yes	FALSE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4－1 が Yes	FALSE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報を入手可能	質問 4－2 が Yes	FALSE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする
条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。

				また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4-4 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4-5 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4-6 が Yes	FALSE	訓練関連データを想定攻撃者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4-7 が Yes	FALSE	システムの詳細な仕様を公開せず、想定攻撃者に真の正解ラベル (Ground Truth) を推測されないようにする
条件 5-1	転移性を利用したモデルの開発	質問 5-1 が Yes	FALSE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。

条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	FALSE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	FALSE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	FALSE	訓練済みモデルを管理し、外部に流出しないようにする
条件 7-1	類似データを 1 個以上入手可能	質問 7－1 が Yes	FALSE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを千個以上入手可能	質問 7－2 が Yes	FALSE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを 1 万個以上入手可能	質問 7－3 が Yes	FALSE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 8-1	扱うデータがテーブルデータ	質問 8－1 が Yes	TRUE	テーブルデータを扱う AI システムなのか画像データを扱う AI システムなのか、利用形態が適切であるかを確認する

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：なし

ポイズニング攻撃：なし

モデル抽出攻撃：なし

モデルインバージョン攻撃：なし

メンバシップ推測攻撃：なし

(iv) 分析結果

第三者はプラントの外部センサを細工し、好きなデータを入力できると想定。ただし、

結果を入手できないため、想定した全ての攻撃シナリオが攻撃困難と判定された。

・セキュリティリスク分析結果の考察

影響分析により、AI の誤判断の被害については、対処必要性が大や中のものがあり、対応が必要と考えられる。AI の誤判断被害は回避攻撃とポイズニング攻撃により実施される可能性があるので、これらの攻撃への対処が必要となる。

脅威分析からは、想定攻撃者が第三者のケースを想定したが、この場合には、いずれの攻撃も「攻撃困難」と判定された。

回避攻撃もポイズニング攻撃も実施困難であることから、影響分析で明らかになつた誤判断被害は直ちには実施することは難しいと判断できる。ただし影響分析により、人命に関わる被害も生じる可能性があることから、専門家を交えたより詳細な分析が必要かもしれない。

II-10.1.3. 性別・年齢推定 AI

仕様：撮影した映像に含まれる人物の性別・年齢を予測する AI

物体認識と性別・年齢判定の 2 つの AI の組み合わせとなる。訓練はカメラ映像に対して人手でラベル付けして行う。訓練は信頼できる人が行う。推論は店舗内を録画したカメラ映像から画像を抜き取り、モデルに入力することで行う。結果は分析者のみが知ることができ、販売促進活動などに利用する。

・影響分析

1. ヒアリングシート

項目	記入内容
目的	撮影した映像に含まれる人物の性別・年齢を予測する
訓練者	信頼できる人が自社で訓練
訓練済モデルの秘密度	人物認識部分は秘密ではない。性別・年齢予測部分は秘密
訓練データの内容	人物の映った画像、画像と年齢の情報
訓練データの入手先	店舗のカメラ映像
訓練データの公開度	非公開
AI に関する人々	店舗画像に移っている人々、訓練データ取扱者、サービス運営会社、サービス利用者
AI に関する物品	画像を録画するカメラ、画像情報を保存する機器、システム自身

2. 影響分析の準備シート

項目	記入内容
目的の反転	人物の性別・年齢を正確に予測できない
AI の誤判断の想定被害者	年齢・性別予測 AI のサービス利用者
AI の誤判断の想定被害物品	AI システム
訓練済モデル漏洩の想定被害者	サービス運営会社
訓練データ漏洩の想定被害者	店舗画像に映っている人々

3. AI の誤判断被害の分析シート

○AI の誤判断被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	サービス提供場所で
どうして	AI の誤判断を起こさせて
誰に（何に）	サービス利用者に
どうなる	正しい予測を与えない
「どうなる」により生じる具体的な影響	サービス利用によるマーケティング、分析に悪影響を及ぼす。また、提供側には賠償やサービス提供不能による金銭的損失が及ぶ
引き起こされる被害	マーケティング、分析ができず、誤ったマーケティングをすることでの利益の逸失（金銭的被害） 損害賠償が発生する（サービス提供者の金銭被害）
対処必要性	中

4. 情報漏洩被害の分析シート

○訓練済モデルの漏洩被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	性別・年齢予測 AI システムで
どうして	訓練済モデルを漏洩（奪取）して
誰に	サービス提供者
どうなる	訓練済モデルを盗まれる
引き起こされる被害	顧客を奪われ、売上損失（金銭的被害）
対処必要性	中

○訓練データの漏洩被害のテーブル

被害例 1

項目	記入内容
誰が	攻撃者
なぜ	攻撃することで
どこで	性別・年齢予測 AI システムで
どうして	訓練データを漏洩（奪取）して
誰に	店舗画像に映っている人々
どうなる	訓練データを盗まれる
引き起こされる被害	訓練データに映っている人と年齢がばれ、 プライバシーの被害が発生する（精神的被害） プライバシー被害が発生した際に、サービス提供者に賠償が生じる可能性がある（その他の被害）
対処必要性	中

・脅威分析

1. 想定攻撃者=AI システム開発者

(i)質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	Yes
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	-
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	Yes
2-4A	【2-3A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	Yes
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-4B	【2-3B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	Yes
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	Yes
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	Yes

4-2	AI システムに用いられた訓練データの統計情報を想定攻撲者は知ることができますか？	Yes
4-3	AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ)を想定攻撲者が、1 個以上入手できますか？	Yes
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ)を想定攻撲者が、1,000 個程度以上入手できますか？	Yes
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ)を想定攻撲者が、10,000 個程度以上入手できますか？	Yes
4-6	訓練関連データに関して、想定攻撲者が 1 個以上入手できますか？	Yes
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撲者が入手できますか？	Yes
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	Yes
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撲者が知ることができますか？	Yes
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撲者が知ることができますか？	Yes
6-3	訓練済みモデルそのものを想定攻撲者が何らかの方法で入手することができますか？	Yes
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撲者が 1 個以上、何らかの手段で準備・入手できますか？	Yes
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撲者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撲者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
8-1	システムで扱っているデータはテーブルデータですか？	No

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1-1 A または質問 1-1 B が Yes	TRUE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2-1 A または質問 2-1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2-2 A または質問 2-2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2-3 A または質問 2-3 B が Yes	TRUE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2-4 A または質問 2-4 B が Yes	TRUE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3-1、または質問 3-2 が Yes	TRUE	判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3-2 が Yes	TRUE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4-1 が Yes	TRUE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報を入手可能	質問 4-2 が Yes	TRUE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする

条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4－4 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes	TRUE	訓練関連データを想定攻撲者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes	TRUE	システムの詳細な仕様を公開せず、想定攻撲者に真の正解ラベル (Ground Truth) を推測されないようにする

条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes	TRUE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	TRUE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	TRUE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	TRUE	訓練済みモデルを管理し、外部に流出しないようする
条件 7-1	類似データを1個以上入手可能	質問 7－1 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを千個以上入手可能	質問 7－2 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを1万個以上入手可能	質問 7－3 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 8-1	扱うデータがテーブルデータ	質問 8－1 が Yes	FALSE	テーブルデータを扱うAIシステムなのか画像データを扱うAIシステムなのか、利用形態が適切であるかを確認する

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：A1, A2, A3, A4

ポイズニング攻撃：P1, P2, P3

モデル抽出攻撃：X1, X2, X3, X5, X6

モデルインバージョン攻撃 : I1, I2, I3

メンバシップ推測攻撃 : M1, M2, M3, M4, M5, M6, M7, M8

(iv) 分析結果

X4 以外のすべてのシナリオで攻撃実施可能と判定された。開発者は権限が大きいためこのような結果となったと考えられる。X4 は AI が扱うデータがテーブルデータであった際のシナリオのため、こちらは不成立となった。

2. 想定攻撃者＝ラベル付け担当者

(i) 質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	-
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	No
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	Yes
2-4A	【2-3A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	Yes
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は【2-1B】において	-

	て、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	
2-4B	【2-3B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	No
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	No
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	No
4-2	AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？	No
4-3	AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、1 個以上入手できますか？	No
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ) を想定攻撃者が、1,000 個程度以上入手できますか？	No
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、10,000 個程度以上入手できますか？	No
4-6	訓練関連データに関して、想定攻撃者が 1 個以上入手できますか？	No
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撃者が入手できますか？	Yes
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	Yes
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撃者が知ることができますか？	No
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撃者が知ることができますか？	No
6-3	訓練済みモデルそのものを想定攻撃者が何らかの方法で入手	No

	することができますか？	
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？	Yes
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
8-1	システムで扱っているデータはテーブルデータですか？	No

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1-1 A または質問 1-1 B が Yes	FALSE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2-1 A または質問 2-1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2-2 A または質問 2-2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2-3 A または質問 2-3 B が Yes	TRUE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2-4 A または質問 2-4 B が Yes	TRUE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果を入手可能	質問 3-1、または質問 3-2 が Yes	FALSE	判定結果を想定攻撃者に提示しないようにする

条件 3-2	確信度を入手可能	質問 3－2 が Yes	FALSE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4－1 が Yes	FALSE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報が入手可能	質問 4－2 が Yes	FALSE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする
条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4－4 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入

				手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes	FALSE	訓練関連データを想定攻撃者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes	TRUE	システムの詳細な仕様を公開せず、想定攻撃者に真の正解ラベル (Ground Truth) を推測されないようにする
条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes	TRUE	信頼できる入手先から得られるモデルのみをシステムに組み込む。あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	FALSE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	FALSE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	FALSE	訓練済みモデルを管理し、外部に流出しないようにする
条件 7-1	類似データを 1 個以上入手可能	質問 7－1 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを 千個以上入手可能	質問 7－2 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを 1 万個以上入手可能	質問 7－3 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする

条件 8-1	扱うデータが テーブルデータ	質問 8-1 が Yes	FALSE	テーブルデータを扱う AI システムなのか画像 データを扱う AI システム なのか、利用形態が適切 であるかを確認する
--------	-------------------	-----------------	-------	--

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：なし

ポイズニング攻撃：P2

モデル抽出攻撃：なし

モデルインバージョン攻撃：なし

メンバシップ推測攻撃：なし

(iv) 分析結果

P2 のみ成立となった。想定攻撃者は訓練データにラベルを付けるだけであり、出力結果を得ることができない。よって大半の攻撃は実施困難となった。P2 はモデルの構造に起因しており、モデルを流用して AI を構築している際に、流用部分がはじめから汚染されている可能性を懸念してこの判断となっている。

3. 想定攻撃者=分析者

(i) 質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	-
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	No
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes

	て、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	
2-4A	【2-3A】が Yes であった場合、想定攻撃者は 【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	Yes
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-4B	【2-3B】が Yes であった場合、想定攻撃者は 【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	Yes
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	Yes
4-1	推論対象データや訓練データを作成できるフォーマット情報（データ形式、サイズの情報、画像の種類、データの次元等のメタ情報）を想定攻撃者は知ることができますか？	No
4-2	AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？	No
4-3	AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、1 個以上入手できますか？	Yes
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ) を想定攻撃者が、1,000 個程度以上入手できますか？	No
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ) を想定攻撃者が、10,000 個程度以上入手できますか？	No
4-6	訓練関連データに関して、想定攻撃者が 1 個以上入手できま	Yes

	すか？	
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撃者が入手できますか？	No
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	Yes
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撃者が知ることができますか？	No
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撃者が知ることができますか？	No
6-3	訓練済みモデルそのものを想定攻撃者が何らかの方法で入手することができますか？	No
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？	Yes
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
8-1	システムで扱っているデータはテーブルデータですか？	No

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1 – 1 A または質問 1 – 1 B が Yes	FALSE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2 – 1 A または質問 2 – 1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2 – 2 A または質問 2 – 2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する

条件 2-3	推論処理を 1 万個以上で実行可能	質問 2 – 3 A または質問 2 – 3 B が Yes	TRUE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2 – 4 A または質問 2 – 4 B が Yes	TRUE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3 – 1、または質問 3 – 2 が Yes	TRUE	判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3 – 2 が Yes	TRUE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4 – 1 が Yes	FALSE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報が入手可能	質問 4 – 2 が Yes	FALSE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする
条件 4-3	システムデータを 1 個以上入手可能	質問 4 – 3 が Yes	TRUE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4 – 4 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ

				情報を想定攻撃者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撃者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撃者が入手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes	TRUE	訓練関連データを想定攻撃者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes	FALSE	システムの詳細な仕様を公開せず、想定攻撃者に真の正解ラベル (Ground Truth) を推測されないようにする
条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes	TRUE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	FALSE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	FALSE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	FALSE	訓練済みモデルを管理し、外部に流出しないようにする

条件 7-1	類似データを 1 個以上入手 可能	質問 7 – 1 が Yes	TRUE	システムの利用目的や訓 練関連データの詳細な仕 様を想定攻撃者が入手、 推定できないようにする
条件 7-2	類似データを 千個以上入手 可能	質問 7 – 2 が Yes	TRUE	システムの利用目的や訓 練関連データの詳細な仕 様を想定攻撃者が入手、 推定できないようにする
条件 7-3	類似データを 1 万個以上入 手可能	質問 7 – 3 が Yes	TRUE	システムの利用目的や訓 練関連データの詳細な仕 様を想定攻撃者が入手、 推定できないようにする
条件 8-1	扱うデータが テーブルデー タ	質問 8 – 1 が Yes	FALSE	テーブルデータを扱う AI システムなのか画像 データを扱う AI シス テムなのか、利用形態が適 切であるかを確認する

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：A1, A2, A3, A4

ポイズニング攻撃：P2

モデル抽出攻撃：X2

モデルインバージョン攻撃：I1, I3

メンバシップ推測攻撃：M1, M2, M3, M5, M8

(iv) 分析結果

回避攻撃（敵対的サンプル）については全シナリオが成立した。分析者も自身でモデルを任意回数実行可能で、かつ、推論結果を入手可能であるためと考えられる。P2 は構築の際にモデルを流用している際に起こりうる攻撃、X2 は訓練関連データを入手可能な際に起こりうる攻撃である。他の攻撃シナリオもいくつか実施可能であることが示唆されている。メンバシップ推測攻撃は確信度が入手できるため多くのシナリオが実施可能と判定された。

4. 想定攻撃者=録画される人々（店舗内の人）

(i) 質問への回答

質問番号	質問	回答
1-1A	想定攻撃者の意思で訓練処理を行うことができる AI システムにおいて、自身の意図した数種類のデータで想定攻撃者が訓練処理を実行することができますか？	-
1-1B	想定攻撃者でない人が訓練処理を行う AI システム、あるいは自動で訓練処理を行う AI システムにおいて、想定攻撃者が意図したデータを訓練データに混入できますか？	No
2-1A	想定攻撃者が準備した推論対象データ 1 個以上に対して推論処理を実行することができますか？	Yes
2-2A	【2-1A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000 個以上に対して推論処理を実行することができますか？	Yes
2-3A	【2-2A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 10,000 個以上に対して推論処理を実行することができますか？	Yes
2-4A	【2-3A】が Yes であった場合、想定攻撃者は【2-1A】において、意図したデータ 1,000,000 個以上に対して推論処理を実行することができますか？	No
2-1B	想定攻撃者が推論対象データを 1 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-2B	【2-1B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-3B	【2-2B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 10,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
2-4B	【2-3B】が Yes であった場合、想定攻撃者は【2-1B】において、推論対象データを 1,000,000 個以上置き換えたり、混入したりすることで、推論処理に通すことができますか？	-
3-1	想定攻撃者にモデルの判定結果を提示しますか？ あるいは、想定攻撃者は判定結果を類推することができますか？	No
3-2	モデルの確信度を一部でも想定攻撃者に提示しますか？	No
4-1	推論対象データや訓練データを作成できるフォーマット情報	No

	(データ形式、サイズの情報、画像の種類、データの次元等のメタ情報)を想定攻撃者は知ることができますか？	
4-2	AI システムに用いられた訓練データの統計情報を想定攻撃者は知ることができますか？	No
4-3	AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ)を想定攻撃者が、1 個以上入手できますか？	No
4-4	【4-3】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or テストデータ or 推論対象データ)を想定攻撃者が、1,000 個程度以上入手できますか？	No
4-5	【4-4】が Yes であった場合、AI システムへの入力データそのもの(訓練データ or バリデーションデータ or テストデータ or 推論対象データ)を想定攻撃者が、10,000 個程度以上入手できますか？	No
4-6	訓練関連データに関して、想定攻撃者が 1 個以上入手できますか？	No
4-7	AI システムへ入力したデータに対する正解ラベルを想定攻撃者が入手できますか？	No
5-1	外部や内部から入手した訓練済みモデルを一部でも流用し、転移性を利用して AI を構築していますか？ あるいは、AutoML を利用して AI を構築していますか？	Yes
6-1	推論処理の際に入力された推論対象データに対する損失の情報を想定攻撃者が知ることができますか？	No
6-2	推論処理の際に入力された推論対象データに対する勾配の情報を想定攻撃者が知ることができますか？	No
6-3	訓練済みモデルそのものを想定攻撃者が何らかの方法で入手することができますか？	No
7-1	AI システムの仕様として想定される入力データと類似のデータ（ほぼ同じ用途、ほぼ同じ種類・ジャンルのデータ）を、想定攻撃者が 1 個以上、何らかの手段で準備・入手できますか？	Yes
7-2	【7-1】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 1,000 個程度以上、何らかの手段で準備・入手できますか？	Yes
7-3	【7-2】が Yes であった場合、AI システムの仕様として想定するデータと類似のデータを、想定攻撃者が 10,000 個程度以上、何らかの手段で準備・入手できますか？	Yes

8-1	システムで扱っているデータはテーブルデータですか？	No
-----	---------------------------	----

(ii) 条件合致性判定

攻撃実施可能条件	内容	TRUE になる条件	判定結果 (TRUE/FALSE)	FALSE にする対策案
条件 1-1	訓練処理の自由な実行が可能	質問 1-1 A または質問 1-1 B が Yes	FALSE	想定攻撃者が訓練処理を実行できないようにする
条件 2-1	推論処理を 1 個以上で実行可能	質問 2-1 A または質問 2-1 B が Yes	TRUE	想定攻撃者が推論処理を実行できないように設定する
条件 2-2	推論処理を千個以上で実行可能	質問 2-2 A または質問 2-2 B が Yes	TRUE	想定攻撃者がデータ 1,000 個以上に対して推論処理を実行できないように設定する
条件 2-3	推論処理を 1 万個以上で実行可能	質問 2-3 A または質問 2-3 B が Yes	TRUE	想定攻撃者がデータ 10,000 個以上に対して推論処理を実行できないように設定する
条件 2-4	推論処理を 100 万個以上で実行可能	質問 2-4 A または質問 2-4 B が Yes	FALSE	想定攻撃者がデータ 1,000,000 個以上に対して推論処理を実行できないように設定する
条件 3-1	推論結果入手可能	質問 3-1、または質問 3-2 が Yes	FALSE	判定結果を想定攻撃者に提示しないようにする
条件 3-2	確信度入手可能	質問 3-2 が Yes	FALSE	判定結果の確信度を想定攻撃者に提示しないようにする
条件 4-1	データのメタ情報を入手可能	質問 4-1 が Yes	FALSE	訓練関連データや推論対象データのメタ情報を想定攻撃者が入手、推定できないようにする
条件 4-2	システムデータの統計情報が入手可能	質問 4-2 が Yes	FALSE	訓練関連データや統計情報を想定攻撃者が入手、推定できないようにする

条件 4-3	システムデータを 1 個以上入手可能	質問 4－3 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-4	システムデータを千個以上入手可能	質問 4－4 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-5	システムデータを 1 万個以上入手可能	質問 4－5 が Yes	FALSE	訓練関連データや過去に使用した推論対象データを想定攻撲者が入手できないようにする。 また、AI システムのタスクや入力データのメタ情報を想定攻撲者が入手、推定できないようにする。
条件 4-6	訓練関連データを 1 個以上入手可能	質問 4－6 が Yes	FALSE	訓練関連データを想定攻撲者が入手、推定できないようにする
条件 4-7	データの正解ラベルが入手可能	質問 4－7 が Yes	FALSE	システムの詳細な仕様を公開せず、想定攻撲者に真の正解ラベル (Ground Truth) を推測されないようにする

条件 5-1	転移性を利用したモデルの開発	質問 5－1 が Yes	TRUE	信頼できる入手先から得られるモデルのみをシステムに組み込む。 あるいは転移性を用いないようにする。
条件 6-1	データに対する損失が入手可能	質問 6－1 が Yes	FALSE	損失情報を想定攻撃者が入手できないようにする
条件 6-2	データに対する勾配が入手可能	質問 6－2 が Yes	FALSE	勾配情報を想定攻撃者が入手できないようにする
条件 6-3	訓練済みモデル自体を入手可能	質問 6－3 が Yes	FALSE	訓練済みモデルを管理し、外部に流出しないようする
条件 7-1	類似データを1個以上入手可能	質問 7－1 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-2	類似データを千個以上入手可能	質問 7－2 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 7-3	類似データを1万個以上入手可能	質問 7－3 が Yes	TRUE	システムの利用目的や訓練関連データの詳細な仕様を想定攻撃者が入手、推定できないようにする
条件 8-1	扱うデータがテーブルデータ	質問 8－1 が Yes	FALSE	テーブルデータを扱うAIシステムなのか画像データを扱うAIシステムなのか、利用形態が適切であるかを確認する

(iii) 成立した攻撃シナリオ（アタックツリーより判定）

回避攻撃（敵対的サンプル）：なし

ポイズニング攻撃：P2

モデル抽出攻撃：なし

モデルインバージョン攻撃：なし
メンバシップ推測攻撃：なし

(iv) 分析結果

P2 のみ成立となった。P2 はモデルの構造に起因しているので実施可能となった。P2 は流用したモデルがはじめから汚染させていた際に起こりうる攻撃であり、想定攻撃者とした第三者が実際に汚染できるわけではない。結果的に第三者による攻撃は考えにくい。

・セキュリティリスク分析結果の考察

影響分析により、いずれの被害についても、対処必要性が中となった。対応をするかどうかは分析で明らかになった被害に基づいて運営者が決める必要がある。

脅威分析により、想定攻撃者が AI システム開発者と分析者のケースで全攻撃が実施可能と判定された。これらの想定攻撃者は内部犯であり、内部犯が存在すると全ての攻撃が実施できると判断される。想定攻撃者が、ラベル付け担当者と録画される人々のケースでは、シナリオ P2 のみが実施可能となった。P2 はモデルの転移性を使った開発をした際に初めからモデルが汚染されているケースのシナリオである。P2 は十分に信頼できるソースから入手したモデルを利用した場合には汚染が考えにくいため、十分に信頼できる場所からのモデルの入手を行うことで、想定した全ての攻撃が困難となる。

両分析により、被害の度合いはいずれも「中」であるが、それを実施できるのは内部犯のみであり、内部犯に注意していれば、外部からの攻撃はモデルが汚染されているケースを除いて実施困難であると判断できる。従って信頼できるモデルを利用して開発をすることが求められる。

II-11. まとめ

本ガイドラインでは、AI 開発者が自身で影響分析を行うための分析技術の構築方法として AI 影響分析を紹介した。また、AI 影響分析の構築例を例示した。本技術により、AI システムが機械学習特有の攻撃で攻撃された際の被害の種類や大きさを見極めることができる。さらに、脅威分析を行うための分析技術の構築方法として選択回答式 AI セキュリティリスク問診 (AI リスク問診) を紹介し、AI リスク問診の構築例を例示した。本技術によって得られたアタックツリーの成立・不成立の情報より、成立したアタックツリーに対応する攻撃シナリオは実施可能になると判断できる。成立したアタックツリーに対応する攻撃を実施困難にするためには、アタックツリーを不成立にするための条件を考察し、不成立にするための仕様変更を行うことで実施する。本技術は AI 開発者が自身で分析して対応策を考えるための支援技術に相当し、自身での対応策検討を行ったり、本技術の分析結果を参考資料として AI セキュリティ専門家へ相談する際に利用したりすることもできる。なお、本技術によって得られた対応案を何らかの状況、条件で実施できない時には AI セキュリティ専門家に相談して専用の対策を検討して頂きたい。本技術の今後についてはさらなる攻撃シナリオへの対応が想定される。本ガイドラインでは、AI 影響分析と AI リスク問診の実行例を示し、両者を組み合わせた際の分析結果についてまとめた。これらの技術を活用し、機械学習システムのセキュリティ強化を検討して頂きたい。

II-12. 参考文献

- [II-1] 総務省 AI ネットワーク社会推進会議, “AI 利活用ガイドライン～AI 利活用のためのプラクティカルリファレンス～”
https://www.soumu.go.jp/main_content/000637097.pdf
- [II-2] K. Eykholt, I. Evtimov, E. Fernandes, B. Li, A. Rahmati, C. Xiao, A. Prakash, T. Kohno, D. Song, “Robust Physical-World Attacks on Deep Learning Models”, CVPR 2018.
- [II-3] 経済産業省商務情報政策局サイバーセキュリティ課, “機器のサイバーセキュリティ確保のためのセキュリティ検証の手引き 別冊1 脅威分析及びセキュリティ検証の詳細解説書”,
<https://www.meti.go.jp/press/2021/04/20210419003/20210419003-2.pdf>
- [II-4] European Union Agency for Cybersecurity (ENISA), “Artificial Intelligence Cybersecurity Challenges”, 2020.
<https://www.enisa.europa.eu/publications/artificial-intelligence-cybersecurity-challenges>
- [II-5] Microsoft, “AI/ML システムと依存関係の脅威のモデル化”, 2019.
<https://docs.microsoft.com/ja-jp/security/engineering/threat-modeling-aiml>
- [II-6] International Electrotechnical Commission, “Failure modes and effects analysis (FMEA and FMECA)”, IEC 60812:2018.
- [II-7] 矢嶋, 乾, 辻, 吉岡, “機械学習特有の攻撃に対する開発者向けセキュリティリスク分析について～機械学習システム開発者向け被害分析手法～”, 電子情報通信学会情報セキュリティ研究会(ISEC), 2023-05.
- [II-8] 矢嶋, 清水, 森川, 大久保, “機械学習システムに潜む AI セキュリティ脆弱性の分析手法に関する一考察”, 2021 年暗号と情報セキュリティシンポジウム
- [II-9] 矢嶋, 及川, 森川, 笠原, 乾, 吉岡, “開発エンジニア向け機械学習セキュリティ脅威分析技術”, 2022 年暗号と情報セキュリティシンポジウム
- [II-10] 矢嶋, 乾, 清水, 笠原, 辻, 吉岡, “AI 開発エンジニア向け機械学習セキュリティ脅威分析技術の拡張”, 2023 年暗号と情報セキュリティシンポジウム
- [II-11] M. Juuti, S. Szryder, S. Marchal, N. Asokan, “PRADA: Protecting against DNN Model Stealing Attacks”, the 4th IEEE European Symposium on Security and Privacy (EuroS&P 2019)
- [II-12] T. Orekondy, B. Schiele, M. Fritz, “Knockoff Nets: Stealing Functionality of Black-Box Models”, arXiv <https://arxiv.org/abs/1812.02766>
- [II-13] R. Shokri, M. Stronati, C. Song, V. Shmatikov, “Membership Inference Attacks Against Machine Learning Models”, 2017 IEEE Symposium on Security and Privacy (S&P).

- [II-14] S. Yeom, I. Giacomelli, M. Fredrikson, S. Jha, “Privacy Risk in Machine Learning: Analyzing the Connection to Overfitting”, 2018 IEEE 31st Computer Security Foundations Symposium (CSP).
- [II-15] A. Salem, Y. Zhang, M. Humbert, P. Berrang, M. Fritz, M. Backes, “ML-Leaks: Model and Data Independent Membership Inference Attacks and Defenses on Machine Learning Models”, The Network and Distributed System Security 2019 (NDSS 2019).
- [II-16] A. Sablayrolles, M. Douze, C. Schmid, Y. Ollivier, Herve Jegou, “White-box vs Black-box: Bayes Optimal Strategies for Membership Inference”, the 36th International Conference on Machine Learning.
- [II-17] Z. Li, Y. Zhang, “Membership Leakage in Label-Only Exposures”, 2021 ACM SIGSAC Conference on Computer and Communications Security (CCS’2021).

機械学習システムセキュリティガイドライン策定委員会メンバーリスト

・現メンバー

乾 真季 (富士通株式会社)
大久保 隆夫 (情報セキュリティ大学院大学)
笠原 史禎 (富士通株式会社)
久連石 圭 (株式会社東芝)
辻 健太郎 (富士通株式会社)
花谷 嘉一 (株式会社東芝)
林 昌純 (帝京平成大学)
矢嶋 純 (富士通株式会社)
吉岡 信和 (早稲田大学)
(敬称略・五十音順)

・元メンバー (所属は策定委員会在籍時のもの)

市原 大暉 (株式会社 NTT データ)
及川 孝徳 (富士通株式会社)
金子 朋子 (国立情報学研究所)
田口 研治 (国立情報学研究所)
森川 郁也 (富士通株式会社)
(敬称略・五十音順)